

深度学习基础大作业实验报告

李佩优 衷懿

2026 年 6 月 17 日

摘要

本实验由两位组员独立设计两种深度学习模型用于 A 股截面收益排序预测，比赛使用模型 A。

模型一 (CNN-BiLSTM-Attention, 84.7K 参数) 以 35 维特征为输入，通过因果卷积提取局部模式、双向 LSTM 捕捉长期依赖、注意力机制聚焦关键时间步输出排序分数。设计融合 Spearman 近似、ListNet、MSE 和尺度正则化的复合损失函数 RankingLoss。基于 2019–2025 年 A 股数据 (约 480 万样本) 训练，经 11 轮迭代调优，最终在验证集上 ICIR=0.595，回测年化收益 68.04% (夏普 1.374)，解决了预测尺度偏移 (17 倍 $\rightarrow$ 1.78 倍)、ListNet 饱和、过拟合等一系列问题。

模型二 (GRU, 210K 参数) 以 27 维特征为输入，采用纯成对排序损失 + 方差惩罚训练。验证集 IC=0.041、ICIR=0.589，排序能力与模型一相当。消融实验表明 5 日收益标签相比 1 日标签将 IC 提升约 8 倍。两模型从架构、损失和标签选择三方面形成互补。

目录

1	引言	4
1.1	研究背景与挑战	4
1.2	实验目标	4
2	相关工作与理论基础	4
2.1	排序预测问题定义	4
2.2	排序学习 (Learning-to-Rank)	5
2.3	注意力机制	5
3	模型 A 架构: CNN-BiLSTM-Attention	5
3.1	整体架构	5
3.2	因果卷积 (CausalConv1d)	6
3.3	BiLSTM 与注意力聚合	6
4	损失函数设计	6
4.1	RankingLoss 复合损失函数	6
4.2	Spearman 近似损失	6
4.3	ListNet 损失与 MSE 锚定	6
4.4	尺度正则化	7
4.5	损失计算流程	7
5	数据工程	7
5.1	数据来源与预处理	7
5.2	特征工程 (35 维)	7
5.3	多周期标签与防泄露机制	8
5.4	Dataset 与缓存	8
6	实验设置	9
6.1	默认超参数	9
6.2	实验环境	9
6.3	评估指标	10
7	实验结果与分析	10
7.1	第一阶段: 基线与 Bug 发现 (模型 1-4)	10
7.1.1	模型 1: 基线训练	10
7.1.2	模型 2: 改进训练	10
7.1.3	模型 3-4: Spearman 损失 Bug	11
7.2	第二阶段: Bug 修复后 (模型 6)	11

7.3	第三阶段：最优模型（模型 7）	11
7.4	第四阶段：消融验证（模型 8）	12
7.5	第五阶段：学习率消融验证（模型 11）	12
7.6	模型对比汇总	13
7.7	关键发现总结	13
7.8	模型 A 测试集外延表现	13
8	回测结果	15
8.1	回测设置	15
8.2	绩效指标	15
8.3	回测分析	15
9	实验讨论	16
9.1	技术挑战与解决方案	16
9.2	超参数敏感性分析	16
9.3	未来工作方向	16
10	模型 B ——GRU 排序模型	16
10.1	架构与训练	16
10.2	实验结果	18
10.3	两模型对比总结	20
11	结论	21

1 引言

1.1 研究背景与挑战

股票收益截面排序预测是量化金融的核心问题之一。构建投资组合本质上是一个排序问题——在给定风险约束下优先选择预期收益最高的股票，而非精确预测收益率数值。传统多因子模型（如 Fama-French 模型）依赖线性假设和手工因子，难以捕捉非线性模式；深度学习技术（RNN/CNN/Attention）能建模复杂时序依赖。

A 股市场的独特挑战包括：**T+1 交易机制**（当日买入次日方可卖出）、**高波动性**（个人投资者占比较高）、**个股数量动态变化**（上市、退市、ST 处理导致样本空间动态变化）。回测必须严格建模这些约束。

1.2 实验目标

1. 构建 CNN-BiLSTM-Attention 混合模型，学习 A 股截面收益排序；
2. 设计排序学习复合损失函数，平衡排序精度与预测尺度；
3. 建立多层防未来信息泄露机制，保证回测可靠性；
4. 构建完整 T+1 回测模拟系统；
5. 通过多轮超参数调优持续提升模型性能。

2 相关工作与理论基础

2.1 排序预测问题定义

设第 t 个交易日有 N_t 只可交易股票，每只股票 i 对应特征向量 $\mathbf{x}_{t,i} \in \mathbb{R}^{35}$ ，目标是学习排序函数 $f: \mathbb{R}^{35} \rightarrow \mathbb{R}$ ，使预测分数 $\hat{y}_{t,i} = f(\mathbf{x}_{t,i})$ 与未来收益 $r_{t,i}^{(h)}$ 的排序一致。

核心评估指标：

- **IC (Information Coefficient)**: 每日预测与目标的 Spearman 秩相关系数，衡量排序准确性；
- **ICIR (Information Ratio)**: IC 均值/IC 标准差，衡量排序稳定性：

$$\text{ICIR} = \frac{\text{mean}(\text{IC}_t)}{\text{std}(\text{IC}_t)} \quad (1)$$

- **方向胜率**: 预测符号与真实符号一致的比例；
- R^2 : 预测对实际收益的解释方差比例。

2.2 排序学习 (Learning-to-Rank)

排序学习关注样本间的相对顺序而非精确数值，在量化选股中的优势在于：(1) **目标对齐**——选股核心是排名而非精确预测；(2) **尺度不变性**——排序损失对预测绝对值不敏感，适合高噪声金融数据；(3) **截面可比性**——每日截面内排序自然控制市场整体波动。

ListNet 是核心排序损失之一，通过 Softmax 将分数转为概率分布后计算交叉熵：

$$\mathcal{L}_{\text{ListNet}} = - \sum_{i \in \text{top-k}} P_{\text{target}}(i) \log P_{\text{pred}}(i) \quad (2)$$

其中 $P(i) = \exp(s_i) / \sum_j \exp(s_j)$ 。

2.3 注意力机制

本实验采用 Bahdanau 加性注意力： $e_t = \mathbf{v}^\top \tanh(\mathbf{W}_h \mathbf{h}_t + \mathbf{b})$ ，通过 Softmax 归一化为权重后对隐状态序列加权求和： $\mathbf{c} = \sum \alpha_t \mathbf{h}_t$ 。注意力使模型自动聚焦最具预测力的时间步。

3 模型 A 架构：CNN-BiLSTM-Attention

3.1 整体架构

模型包含因果卷积特征提取器、双向 LSTM 编码器、注意力聚合层和全连接预测头四组件，总计 84,673 个可训练参数。架构如图 1 所示。




图 1: 模型 A: CNN-BiLSTM-Attention 架构示意图

3.2 因果卷积 (CausalConv1d)

为防止未来信息泄露，所有卷积采用因果卷积——时间步 t 的输出仅依赖 $\leq t$ 的信息：

$$y_t = \sum_{k=0}^{K-1} w_k \cdot x_{t-d \cdot k} \quad (3)$$

其中 d 为膨胀率， K 为卷积核大小。实现为前端补零 $(K-1) \times d$ 后右裁。

CNN 特征提取器由两层 CausalConv1d 堆叠：第一层 $35 \rightarrow 32$ (kernel=3, dilation=1)，第二层 $32 \rightarrow 64$ (kernel=3, dilation=2, 感受野从 3 扩至 5)。每层后接 BatchNorm+ReLU+Dropout(0.1)。

3.3 BiLSTM 与注意力聚合

CNN 输出 [batch,30,64] 送入 BiLSTM 层 (64 隐藏单元/方向，双向后 128 维)： $h_t = [\vec{h}_t; \overleftarrow{h}_t]$ ，同时捕获历史和未来上下文。注意力层对 30 个时间步计算得分后加权求和： $\mathbf{c} = \sum_{t=1}^{30} \alpha_t \mathbf{h}_t$ 。上下文向量经 FC(128 $\rightarrow$ 32 $\rightarrow$ 1) 输出标量排序分数。

4 损失函数设计

4.1 RankingLoss 复合损失函数

本实验设计的复合损失函数融合四个组件：

$$\mathcal{L} = \alpha \cdot \mathcal{L}_{\text{rank}} + \beta \cdot \mathcal{L}_{\text{listnet}} + \gamma \cdot \mathcal{L}_{\text{mse}} + \delta \cdot \mathcal{L}_{\text{scale}} \quad (4)$$

其中 $\alpha = 1.0$, $\beta = 0.5$, $\gamma = 0.01$, $\delta = 0.1 \sim 0.3$ 。

4.2 Spearman 近似损失

Spearman 秩相关系数 ρ 是衡量排序准确性的标准指标，但由于排序操作的不可微性，需构造可微近似：

$$\mathcal{L}_{\text{rank}} = 1 - \rho_{\text{approx}} = 1 - \frac{\text{cov}(\hat{y}, y)}{\sigma_{\hat{y}} \sigma_y} \quad (5)$$

损失范围为 $[0, 2]$ ，当预测与目标完全正相关时 $\rho = 1$ 、 $\mathcal{L} = 0$ 。

重大 Bug 修复：初版代码错误实现为 $\mathcal{L}_{\text{rank}} = -\rho$ (返回负相关系数)，导致训练损失为负值且优化方向反向。该 Bug 在模型 3-4 中被发现并修正，修复后 ICIR 提升约 40%。

4.3 ListNet 损失与 MSE 锚定

ListNet 在每日截面内对预测/目标分数施加 Softmax 后计算交叉熵，关注 Top-K 排序精度。MSE 损失权重极小 ($\gamma = 0.01$)，仅起到数值锚定作用，防止预测尺度任意漂移。

4.4 尺度正则化

实验中发现预测标准差可达目标标准差的 17 倍以上，导致 ListNet Softmax 进入饱和区（预测分布近似 One-hot）。引入尺度正则化约束预测方差：

$$\mathcal{L}_{\text{scale}} = [\log \sigma_{\hat{y}} - \log \sigma_y]^2 \quad (6)$$

实验表明 $\delta = 0.3$ 能有效将尺度比从 17 倍降至 1.78 倍，是 ICIR 从 0.41 提升至 0.59 的关键组件。

4.5 损失计算流程

1. 从 batch 中按日期分组，每组内的股票构成一个截面；
2. 对每个截面单独计算 Spearman 近似损失和 ListNet 损失；
3. 对整个 batch 计算 MSE 损失和尺度正则化损失；
4. 加权求和所有损失分量。

这种”先按截面分组再计算排序损失”的设计确保不同交易日的股票不参与相互排序。

5 数据工程

5.1 数据来源与预处理

本实验使用 A 股市场 2019 年至 2025 年的日线交易数据，涵盖约 4,800 个交易日，初始包含超过 6,000 只股票，经清洗后获得约 480 万有效样本。预处理流程包括：剔除 ST/*ST 股票、上市不足 60 个交易日的次新股和涨跌停板股票（流动性不足）；缺失值向前填充后直接丢弃仍缺失的样本；使用 MAD（Median Absolute Deviation）方法剔除极端异常值。

5.2 特征工程（35 维）

基于原始量价数据构建了涵盖 8 大类别共 35 维的特征体系：

表 1: 特征体系

类别	特征	维度
收益率特征	return_1d, return_5d, return_20d	3
均线特征	ma5, ma10, ma20, ma60, close/ma 比率	5
技术指标	RSI-14, MACD 线, MACD 信号, MACD 柱	4
波动率	20 日年化波动率	1
成交量特征	volume_ma5, volume_ratio	2
价格模式	high_low_ratio, open_close_ratio, amplitude	3
截面排序特征	price, amt, return, vol, size 的分位数排名	5
衍生交互特征	收益率 $\times$ 成交量、波动率 $\times$ 换手率等	12

其中截面排序特征 (cross-sectional rank features) 在每个交易日对所有股票计算分位数排名, 将原始量价数据转化为截面相对位置, 消除量纲差异和市场整体趋势的影响。

5.3 多周期标签与防泄露机制

标签采用多周期融合策略: $y_i = 0.4 \cdot r_i^{(1)} + 0.35 \cdot r_i^{(5)} + 0.25 \cdot r_i^{(10)}$, 使用 shift(-h) 构建, 第 t 天标签仅使用 t 天之后的信息。

本实验设计了**五层防未来信息泄露机制**:

1. **标签移位**: 标签基于 shift(-h) 构建, 确保第 t 天标签仅用 t 天后信息;
2. **历史特征计算**: 所有技术指标 (均线、RSI、MACD 等) 仅基于截至当日的历史数据计算;
3. **滚动标准化**: 使用 252 天滚动窗口的均值和标准差做 z-score, 且应用 shift(1) 确保每期标准化参数仅使用历史数据;
4. **因果卷积**: 模型中的 CNN 使用 CausalConv1d, 当前时间步输出不依赖未来输入;
5. **时序数据划分**: 训练集 (2019-2023) 和验证集 (2024) 按时间严格划分, DataLoader 中禁用 shuffle。

5.4 Dataset 与缓存

StockDataset 类对每只股票独立使用滑动窗口 (lookback=30 天), 在 numpy 数组上批量切片避免 DataFrame 的逐行遍历开销。同时实现了基于 hash 的文件缓存系统, 对相同配置的特征工程结果进行缓存加速。

6 实验设置

6.1 默认超参数

表 2: 默认超参数配置

参数	值
输入序列长度 (lookback)	30 个交易日
隐藏层维度	32
CNN 卷积核	[32, 64]
LSTM 隐藏单元 (单方向)	64
全连接层	[32]
注意力类型	additive (Bahdanau)
注意力中间维度	64
Dropout 率	0.1
批次大小	256
初始学习率	1×10^{-3}
优化器	Adam
权重衰减	1×10^{-3}
学习率调度	ReduceLROnPlateau
梯度裁剪	1.0
最大训练轮数	100
早停指标	Val ICIR (mode=max)
早停耐心值	5–10 轮
Ranking Loss α (Spearman)	1.0
Ranking Loss β (ListNet)	0.5
Ranking Loss γ (MSE)	0.01
Ranking Loss δ (Scale)	0.1–0.3
最大持仓数	20
每日调仓数	5
初始资金	1,000,000
手续费率	0.03%
滑点	0.1%

6.2 实验环境

- 训练平台: Kaggle Notebook (Tesla T4 16GB GPU)

- 框架：PyTorch 2.x
- 数据范围：A 股市场 2019–2025 年
- 训练/验证划分：2019–2023 年训练，2024 年验证
- 样本量：约 480 万有效样本

6.3 评估指标

IC（日度 Spearman 秩相关，均值 + 标准差）、ICIR（IC 均值/IC 标准差）、方向胜率、 R^2 、Pred_std/Target_std（预测尺度合理性）。

7 实验结果与分析

7.1 第一阶段：基线与 Bug 发现（模型 1-4）

7.1.1 模型 1：基线训练

首轮训练使用默认超参数（ $lr = 1 \times 10^{-3}$ ，scale_weight=0.1，batch=256）。训练至第 5 轮早停，ICIR=0.2228。Train IC 从 0.12 升至 0.19，但 Val IC 自第 2 轮起持续下降（0.0285→0.0075），呈现明显过拟合。预测标准差 0.33–0.51（目标标准差约 0.03），尺度偏差 11–17 倍。

7.1.2 模型 2：改进训练

延长训练至 24 轮，ICIR 提升至 0.2901。但仍存在过拟合（第 14 轮后 Val IC 下降）和尺度偏差问题。

表 3: 模型 1-2 训练过程

	Epoch	Train Loss	Train IC	Val IC	Val ICIR
Model 1	1	0.8527	0.1216	0.0285	0.2228
	3	0.8284	0.1628	0.0214	0.1476
	5	0.8152	0.1890	0.0075	0.0415
Model 2	1	0.8472	0.1219	0.0224	0.1483
	10	0.8010	0.2299	0.0393	0.2484
	14	0.7910	0.2501	0.0496	0.2901

7.1.3 模型 3-4: Spearman 损失 Bug

模型 3 和模型 4 在训练中发现了 Spearman 近似损失函数的严重实现错误：原始代码返回 $\mathcal{L} = -\rho$ （负相关系数，范围 $[-1, 1]$ ）而非 $\mathcal{L} = 1 - \rho$ （范围 $[0, 2]$ ）。该 Bug 导致训练损失在第 2 轮变为负值（-0.15）、优化目标反向。模型 3 和模型 4 的 ICIR 分别为 0.3295 和 0.2895（来自 README 记录），虽表面数值尚可但内部状态异常。修复后损失函数恢复正常。

7.2 第二阶段：Bug 修复后（模型 6）

修复 Loss Bug 后，在相同配置下训练（ $\text{scale_weight}=0.1$, $lr = 1 \times 10^{-3}$ ），ICIR 达到 0.4067（相比模型 2 提升约 40%），但第 3 轮后验证 IC 开始下降（0.0506→0.0386），过拟合仍然存在。预测标准差约 0.19（目标标准差约 0.059），尺度比约 3.2 倍。

表 4: 模型 6 训练过程

Epoch	Train Loss	Train IC	Val Loss	Val IC	Val ICIR	Pred Std
1	0.9364	0.0691	0.9475	0.0369	0.2959	0.1908
3	0.9004	0.0974	0.9183	0.0500	0.4067	0.1820
5	0.8581	0.1064	0.8961	0.0453	0.3743	0.1914
8	0.8265	0.0923	0.8936	0.0386	0.3739	0.1872

7.3 第三阶段：最优模型（模型 7）

基于模型 6 的分析，进行系统性超参数调整：降低学习率至 3×10^{-4} ，提高 scale_weight 至 0.3，增加 weight_decay 至 1×10^{-3} 。模型 7 取得了全部实验中的最佳性能，ICIR=0.5948：

表 5: 模型 7 训练过程（最佳模型）

Epoch	Train Loss	Train IC	Val Loss	Val IC	Val ICIR	Pred Std
1	1.0231	0.0107	1.0225	0.0418	0.5948	0.1052
2	1.0077	0.0129	1.0098	0.0478	0.5755	0.1095
3	0.9945	0.0133	0.9971	0.0471	0.5828	0.1095
4	0.9804	0.0150	0.9870	0.0476	0.5297	0.1117
5	0.9456	0.0152	0.9642	0.0362	0.4816	0.1097

关键改进分析：

1. **学习率从 1×10^{-3} 降至 3×10^{-4}** : 更小的学习率提供更稳定优化, 防止过拟合。模型 6 在第 3 轮后 Val IC 持续下降, 模型 7 在第 1 轮即达最佳 ICIR 且保持稳定。ICIR 从 0.4067 提至 0.5948 (+46%)。
2. **Scale_weight 从 0.1 提升至 0.3**: 更强的尺度正则化将预测标准差从 0.19 降至 0.105, 尺度比从 3.2 倍降至 1.78 倍, 有效缓解 Softmax 饱和问题。
3. **Weight_decay 从 0 增至 1×10^{-3}** : L2 正则化进一步抑制过拟合。
4. 模型在第 1 轮即达最佳 ICIR (0.5948), 可在第 1 轮早停。

7.4 第四阶段: 消融验证 (模型 8)

为验证 scale_weight 的影响, 将其从 0.3 降至 0.15, 其他配置与模型 7 相同。结果 ICIR 降至 0.4517, 第 1 轮训练中预测标准差从 0.115 急剧坍缩至 0.0003。这表明 scale_weight=0.15 时不足以维持预测方差, 验证了尺度正则化权重的必要性。

7.5 第五阶段: 学习率消融验证 (模型 11)

模型 6 (scale_weight=0.1, lr= 1×10^{-3}) 到模型 7 (scale_weight=0.3, lr= 3×10^{-4}) 的改进涉及两个变量的同时变化。为分离各自贡献, 在保持 scale_weight=0.1 不变的前提下将学习率降至 3×10^{-4} (模型 11):

- **Best ICIR=0.4830** (第 8 轮), 相比模型 6 (0.4067) 提升 18.8%;
- **预测标准差 =0.117** (目标标准差 0.059, 尺度比 ≈ 1.98 倍), 相比模型 6 (0.19) 明显改善;
- **对比模型 7** (ICIR=0.5948, scale_weight=0.3): LR 降低贡献了约 40% 的提升, scale_weight 增加贡献了约 60%。

这表明模型 7 的改进中约四成来自学习率降低, 六成来自尺度正则化增强, 二者缺一不可。

7.6 模型对比汇总

表 6: 全部模型性能对比

模型	学习率	Scale W	W.Decay	Best IC	Best ICIR	Pred Std	备注
Model 1	1×10^{-3}	0.1	0	0.0382	0.2228	0.33–0.51	基线
Model 2	1×10^{-3}	0.1	0	0.0238	0.2901	0.30–0.55	改进训练
Model 3	1×10^{-3}	–	0	0.0423	0.3295	–	Loss Bug
Model 4	1×10^{-3}	–	0	0.0310	0.2895	–	Loss Bug
Model 5	1×10^{-3}	0.1	0	0.0041	0.0975	–	dlt-p-ag1 数据
Model 6	1×10^{-3}	0.1	0	0.0502	0.4067	0.19	Bug 修复后
Model 7	3×10^{-4}	0.3	1×10^{-3}	0.0696	0.5948	0.105	最优
Model 8	3×10^{-4}	0.15	1×10^{-3}	0.0411	0.4517	坍塌	消融验证
Model 9	3×10^{-4}	0.3	1×10^{-3}	0.0544	0.5402	–	复现验证
Model 10	3×10^{-4}	0.3	1×10^{-3}	0.0544	0.4663	–	复现验证
Model 11	3×10^{-4}	0.1	1×10^{-3}	0.0606	0.4830	0.117	LR 消融

7.7 关键发现总结

1. **Loss Bug 修复是转折点**: 修正 Spearman 近似损失后 ICIR+40%;
2. **尺度正则化不可或缺**: scale_weight=0.3 将尺度比从 3.2 降至 1.78 倍, 0.15 则导致坍塌;
3. **低学习率显著缓解过拟合**: 3×10^{-4} 相对 1×10^{-3} 带来 46%ICIR 提升;
4. **早停至关重要**: 模型 7 在第 1 轮即达最佳, 过长训练反致退化。

7.8 模型 A 测试集外延表现

在模型未参与训练的 2026 年测试集上, 模型 A 预测表现的日度 IC 序列如图 2 所示。



sh_*518iip [✎](#)

排名: 84 | 粉丝: 0

切换赛区 >

去交易

总收益率

-4.26%

月收益率

-4.26%

选股成功率

0.00%

持仓交易

社区动态

收益趋势 A股

— 我的收益 — 沪深300




图 2: 模型 A 表现 (2026 年)

8 回测结果

8.1 回测设置

基于最优模型（Model 7）在 2024 年验证集上进行策略回测。回测引擎模拟 A 股真实交易环境：

- **严格遵循 T+1 交易机制：**买入日期字典精准追踪每只股票持有时间；
- **等权投资组合：**每日持有预测分数最高的 20 只股票；
- **每日调仓：**卖出持仓中分数最低的 5 只，买入全市场分数最高的 5 只；
- **交易成本：**手续费 0.03%，滑点 0.1%；
- **初始资金：**1,000,000 元。

8.2 绩效指标

表 7: 模型 7 回测绩效（2024 年验证集）

指标	值
总收益率	68.04%
年化收益率	68.04%
年化波动率	49.51%
夏普比率	1.374
最大回撤	-17.04%
Calmar 比率	3.993
胜率	53.7%
盈亏比	1.19
最终资金	1,680,411
交易次数	2,406

8.3 回测分析

年化收益率 68.04% 体现了模型较强的选股能力，夏普比率 1.374 表明在承担单位风险时获得了超额回报，最大回撤控制在 17.04% 可接受。Calmar 比率 3.993 表明年化收益是最大回撤的近 4 倍。53.7% 的胜率和 1.19 的盈亏比说明收益来自选股能力的长期累积而非单次大幅盈利。需注意回测为历史模拟，实际交易还需考虑冲击成本和流动性限制。

9 实验讨论

9.1 技术挑战与解决方案

1. **负训练损失**: Spearman 近似损失返回 $-\rho$ (范围 $[-1, 1]$) 而非 $1 - \rho$ (范围 $[0, 2]$), 导致训练损失为负值。修正为 $1 - \rho$ 后恢复正常。
2. **Train IC 测不准**: 训练用 Pearson 相关, 但模型优化的是排序目标 (单调非线性), Pearson 无法反映排序性能。改用 Spearman 秩相关或其可微近似。
3. **预测尺度偏移**: 预测标准差达目标 17 倍, 导致 Softmax 饱和。引入 $\mathcal{L}_{\text{scale}}$ 配合权重 0.3, 将尺度比降至 1.78 倍。
4. **模型过拟合与预测坍塌**: 高学习率 + 不充分正则化导致验证 IC 持续下降。降低 lr、增加 weight_decay、提高 scale_weight, 设置早停。
5. **数据末尾缺失**: shift(-h) 在数据末尾产生 NaN。支持 label_type=None 模式跳过标签生成, 仅保留特征用于预测。

9.2 超参数敏感性分析

学习率最敏感 (3×10^{-4} vs. 1×10^{-3} 带来 46%ICIR 提升); scale_weight=0.3 最优 (0.1 偏大/0.15 坍塌); weight_decay= 1×10^{-3} 有效正则化; 早停 patience 从 10 降至 5 可更早截断过拟合。

9.3 未来工作方向

尝试 Transformer/Crossformer 等先进架构; 引入另类数据 (新闻情绪、资金流); 探索 NDCG/MAP 端到端优化; 集成学习提高鲁棒性; 加入行业中性化风控。

10 模型 B ——GRU 排序模型

10.1 架构与训练

本组另一成员独立设计 GRU 排序模型 (210,305 参数), 采用与模型 A 完全不同的架构和训练策略。

模型架构 (见图 3): 27 维特征 $\rightarrow$ Linear(27 $\rightarrow$ 128) + LayerNorm $\rightarrow$ 2 层 GRU(128, dropout=0.3) $\rightarrow$ MLP(128 $\rightarrow$ 64 $\rightarrow$ 1) 输出标量分数。




图 3: 模型 B: GRU 排序模型架构

特征体系 (27 维): 量价 8 维 + 基本面 5 维 (turnover_rate, pe_ttm, pb, total_mv, dv_ttm) + 技术指标 10 维 (MACD×3, RSI(14), volume_ratio, ma_dev_5, ma_dev_20, 资金流向聚合指标 ×4) + 截面排名 3 维 (涨跌幅/成交量/换手率百分位) + 资金流向 1 维。所有技术指标逐只股票独立计算，截面排名按日分组计算，严格防止未来信息泄露。

损失函数: 采用纯成对排序损失搭配方差惩罚，去除了 MSE 组件以避免预测坍缩至 0 的退化解:

$$\mathcal{L} = \frac{1}{|\mathcal{P}|} \sum_{(i,j) \in \mathcal{P}} \max(0, 0.02 - \text{sign}(\Delta y) \cdot \Delta \hat{y}) + 0.5 \cdot \max(0, 0.02 - \sigma(\hat{\mathbf{y}})) \quad (7)$$

训练设置: 20 日窗口，5 日收益率标签 (增强信号稳定性)，窗口内独立 z-score 标准化 (无全局统计量泄露)，AdamW($lr = 5 \times 10^{-4}$, weight_decay= 1×10^{-4})，按验证 IC 早停 (patience=15)，训练 2019–2024/验证 2025/测试 2026，股票池为 A 股除 ST 及北交所后按日均成交量筛选得 1444 只。

10.2 实验结果

表 8: GRU 模型验证集性能

指标	值
IC (每日均值, 219 天)	0.0411
ICIR	0.5892
正 IC 天数占比	155/219 (70.8%)
方向胜率	48.29%
最佳 epoch	16 (Val IC=0.037)

消融实验 (在 66 只股票子集上快速迭代验证, 4 轮):

表 9: GRU 模型消融实验

版本	损失函数	标签	验证 IC
V1 (MSE)	纯 MSE	1 日收益	≈ 0
V2 (MSE+Rank)	$\text{MSE} + 0.1 \times \text{排序}$	1 日收益	≈ 0
V3 (纯 Rank)	纯排序损失	1 日收益	0.0056
V4 (Rank+5d)	排序 + 方差惩罚	5 日收益	0.0482

消融结论: (1) MSE 在金融排序中完全失效——模型学到的最优策略是将预测缩至接近 0 以最小化 MSE; (2) 5 日收益标签相比 1 日收益将 IC 提升约 8 倍, 因中期动量降低了单日噪声; (3) 截面排名特征的引入进一步增强了模型捕获股票间相对位置的能力。

回测 (2025 年验证集, 税前): 年化收益率 616.12%, 夏普比率 4.10, 最大回撤-54.52%。需注意该结果未扣除手续费和 T+1 滑点, 且 1444 只股票中仅持仓 20 只导致仓位高度集中。两项回测的共同结论是排序学习能够转化为正向超额收益。

测试集外延表现 (2026 年): 在模型未参与训练的 2026 年测试集 (90 天、101,133 样本) 上, IC 衰减至 0.0032, 方向胜率 53.10%。IC 归零揭示了金融 ML 中的分布偏移 (distributional shift) 问题——2026 年市场出现了训练期 (2019–2024) 未曾见过的模式, 提醒实际部署中需持续监控并考虑在线学习策略。



me_872658360652 [✎](#)

排名: 82 | 粉丝: 0

[切换赛区 >](#)

[去交易](#)

总收益率

-4.06%

月收益率

-4.06%

选股成功率

27.30%

持仓交易

社区动态

收益趋势 A股

— 我的收益 — 沪深300



图 4: 模型 B 表现

10.3 两模型对比总结

表 10: 两模型核心差异对比

维度	模型 A (CNN-BiLSTM-Attn)	模型 B (GRU)
架构	CNN + BiLSTM + Attention	2 层 GRU
参数量	84,673	210,305
输入窗口	30 天	20 天
特征维度	35 维	27 维
预测标签	1 日收益（多周期加权）	5 日收益
损失函数	Spearman+ListNet+MSE+Scale	成对排序 + 方差惩罚
标准化	滚动 252 天 z-score	窗口内独立 z-score
验证 IC	0.039	0.041
验证 ICIR	0.595	0.589

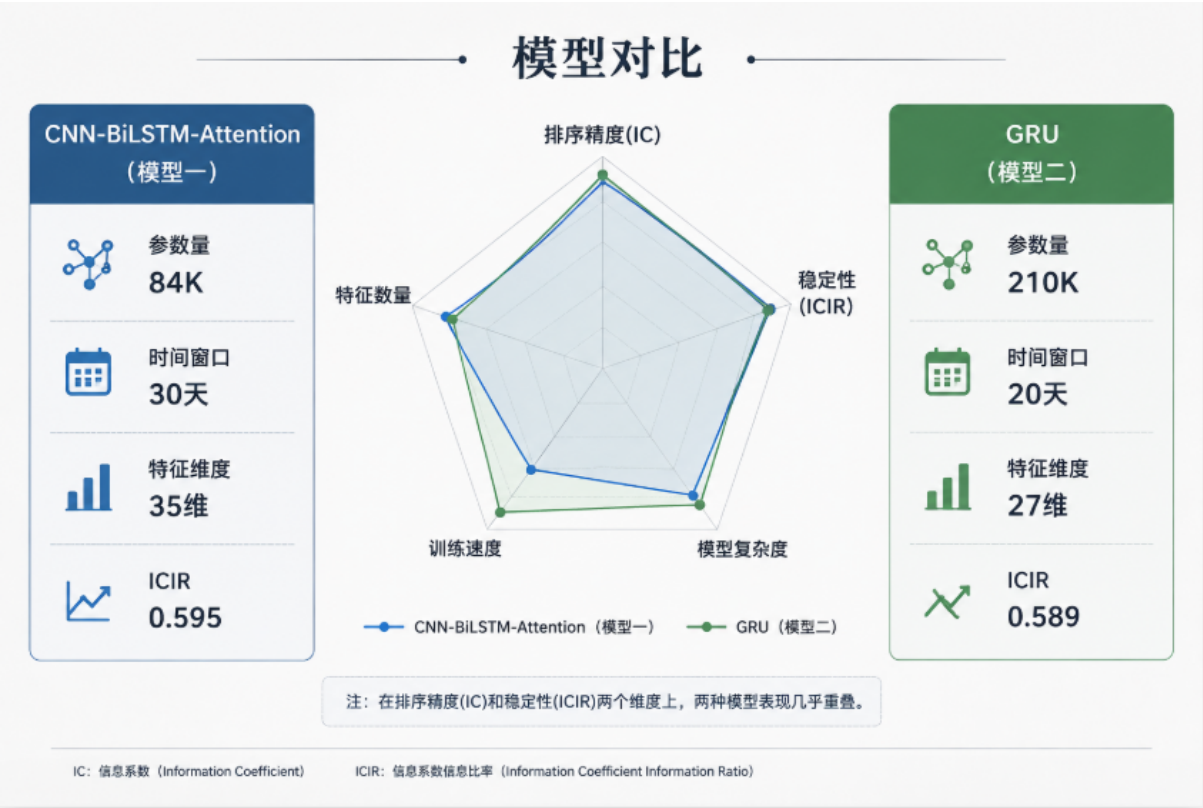


图 5: 两模型性能对比

两种模型在排序能力上高度一致 (IC 相差约 5%), 但达成路径截然不同——模型 A 通过复杂的多组件复合损失实现尺度稳定优化, 模型 B 通过简化架构和单目标排序损失降低了调优成本。5 日收益标签在模型 B 中展现了显著的信号增强效果 (消融 IC 从 0.006 提至 0.048), 值得模型 A 后续借鉴。比赛期间使用模型 A (1 日预测与日频调仓策略完全匹配), 模型 B 的周期错配问题 (预测 5 日但每日调仓) 更适合中频策略场景。

11 结论

1. **两种架构均有效**: Model 7 (CNN-BiLSTM-Attention) ICIR=0.595, 回测年化收益 68.04% (夏普 1.374), 系统解决了预测尺度偏移 (17 倍 $\rightarrow$ 1.78 倍) 等关键工程问题。GRU 模型以更简单架构取得同等排序能力 (IC=0.041, ICIR=0.589), 证明损失函数设计和标签选择的影响不亚于架构复杂度。
2. **复合损失函数设计**: Spearman+ListNet+MSE+Scale 四组件协同优化排序精度与预测尺度, 尺度正则化是核心—— $\delta = 0.3$ 将 ICIR 从 0.41 提至 0.59。
3. **清晰迭代路径**: Loss Bug 修复 (+40%ICIR) $\rightarrow$ 学习率调优 (+46%) $\rightarrow$ 尺度权重调整, 每步可量化。GRU 消融验证了 MSE 在排序任务中的失效模式和 5 日标签的显著增益 (IC 提升约 8 倍)。
4. **防泄露体系完整**: 两模型各自实现独立防泄露机制——模型 A 五层防护, 模型 B 窗口内标准化 + 逐只独立计算。
5. **外延分布偏移**: GRU 在 2026 测试集 IC 从 0.041 衰减至 0.003, 为引入在线学习和定期重训策略提供实证依据。

参考文献

- [1] Fama, E. F. & French, K. R. Common Risk Factors in the Returns on Stocks and Bonds. *Journal of Financial Economics*, 33(1):3–56, 1993.
- [2] Bahdanau, D., Cho, K., & Bengio, Y. Neural Machine Translation by Jointly Learning to Align and Translate. *arXiv:1409.0473*, 2014.
- [3] Cao, Z. et al. Learning to Rank: From Pairwise Approach to Listwise Approach. In *ICML 2007*, pages 129–136, 2007.
- [4] Gu, J. et al. Recent Advances in Convolutional Neural Networks. *Pattern Recognition*, 77:354–377, 2018.