

YOLOv10: 实时端到端目标检测算法解析

论文导读

李佩优

2024 年 6 月 10 日

摘要

目标检测作为计算机视觉领域的一个核心任务，对于自动驾驶、智能监控等应用至关重要。随着深度学习技术的发展，目标检测算法在准确性和速度上都取得了显著进步。YOLO 系列算法以其卓越的实时性能和较高的检测准确率而广受欢迎。本文导读旨在介绍最新版的 YOLO 算法——YOLOv10，它在保持实时检测速度的同时，进一步提高了检测的准确性和模型的效率。




图 1: 在延迟准确性（左）和大小准确度（右）方面与其他公司的比较权衡取舍。我们使用官方预训练模型测量端到端延迟。

1 背景介绍

1.0.1 实施目标检测

实时目标检测一直是计算机视觉领域的研究焦点，其目标是在低延迟下准确预测图像中物体的类别和位置。它在包括自动驾驶、机器人导航和目标跟踪等多种实际应用中

被广泛采用。近年来，研究人员集中于设计基于 CNN（卷积神经网络）的目标检测器以实现实时检测。其中，YOLOs 因其在性能和效率之间熟练的平衡而日益流行。YOLOs 的检测流程包括两个部分：模型前向过程和 NMS 后处理。然而，这两个过程仍有不足，导致准确性-延迟边界的次优。

1.1 YOLOs 的困境

具体来说，YOLOs 在训练期间通常采用一对多的标签分配策略，其中一个真实物体对应多个正样本。尽管这种方法能够带来卓越的性能，但在推理过程中需要 NMS 来选择最佳的正预测结果。这降低了推理速度，并且使得性能对 NMS 的超参数敏感，从而阻碍了 YOLOs 实现最佳的端到端部署。解决这个问题一个方向是采用最近引入的端到端 DETR（Detection Transformer）架构。例如，RT-DETR 展示了一个高效的混合编码器和最小化不确定性的查询选择，将 DETR 推向实时应用领域。然而，部署 DETRs 固有的复杂性阻碍了其在准确性和速度之间达到最优平衡的能力。另一方向是探索基于 CNN 的检测器的端到端检测，这通常利用一对一的分配策略来抑制多余的预测。然而，它们通常会引入额外的推理开销或实现次优性能。

此外，模型架构设计对 YOLOs 的准确性和速度具有重要影响。为了实现更高效和有效的模型架构，研究人员探索了不同的设计策略。提出了各种主要计算单元用于增强特征提取能力，包括 DarkNet、CSPNet、EfficientRep 和 ELAN 等。对于模型的“neck”部分，探索了 PAN、BiC、GD 和 RepGFPN 等来增强多尺度特征融合。此外，还研究了模型扩展策略和重新参数化技术。尽管这些努力取得了显著进展，但 YOLOs 的各个组件仍然缺乏从效率和准确性角度的综合检查。结果，YOLOs 内部仍然存在相当大的计算冗余，导致参数利用效率低下和次优效率。此外，受限的模型能力也导致了较差的性能，为准确性改进留下了充分的空间。

1.2 我们的工作

在这项工作中，我们旨在解决这些问题，并进一步推进 YOLOs 的准确性-速度边界。我们的目标是在整个检测流程中同时针对后处理和模型架构。为此，我们首先通过提出一种一致的双重分配策略来解决后处理中的冗余预测问题，该策略通过双重标签分配和一致的匹配度量实现无需 NMS 的 YOLOs，从而使模型在训练期间享受丰富和谐监督，同时在推理期间消除对 NMS 的需求，从而实现高性能和高效率。其次，我们提出了 YOLOs 模型架构的全面效率-准确性驱动的设计策略。我们从效率和准确性两个角度对 YOLOs 的各个组件进行全面优化。通过这些方法，我们成功实现了具有不同模型尺度的新型实时端到端检测器系列，即 YOLOv10-N / S / M / B / L / X。在标准的目标检测基准测试，即 COCO 上的广泛实验表明，我们的 YOLOv10 在不同模型尺度上的计算-准确性权衡方面显著优于以前的最先进模型。如图 1 1 所示，我们的 YOLOv10-S / X 分别比 RT-DETR-R18 / R101 快 1.8 倍/1.3 倍，在相似的性能下。与

YOLOv9-C 相比, YOLOv10-B 在相同性能下的延迟减少了 46%, 参数减少了 25%。代码: <https://github.com/THU-MIG/yolov10>。

2 历史回顾

2.1 实时目标检测器

实时目标检测的目标是在低延迟下对物体进行分类和定位, 这对于实际应用至关重要。在过去的几年中, 大量的努力都投入到了开发高效检测器中。特别是, YOLO 系列作为主流检测器脱颖而出。YOLOv1、YOLOv2 和 YOLOv3 确定了由三部分组成的典型检测架构, 即 backbone、neck 和 head。YOLOv4 和 YOLOv5 引入了 CSPNet 设计来替代 DarkNet, 并结合了数据增强策略、增强的 PAN 和更多样化的模型尺度等。YOLOv6 展示了 BiC 和 SimCSPSPF 分别用于 neck 和 backbone, 以及 anchor 辅助训练和自蒸馏策略。YOLOv7 引入了 E-ELAN 以获得丰富的梯度流动路径, 并探索了几种可训练的 bag-of-freebies 方法。YOLOv8 提出了 C2f 构建块进行有效的特征提取和融合。Gold-YOLO 提供了先进的 GD 机制来增强多尺度特征融合能力。YOLOv9 提出了 GELAN 来改善架构, 并采用 PGI 增强训练过程。

2.2 端到端目标检测器

端到端目标检测已经成为传统流程的范式转变, 提供了简化的架构。DETR 引入了 transformer 架构, 并采用匈牙利损失来实现一对一匹配预测, 从而消除了手工制作的组件和后处理。从那时起, 提出了各种 DETR 变体以提高其性能和效率。Deformable-DETR 利用多尺度可变形注意力模块加速了收敛速度。DINO 将对比去噪、混合查询选择和前瞻两次方案整合到 DETR 中。RT-DETR 进一步设计了高效的混合编码器, 并提出了最小化不确定性的查询选择, 以提高准确性和延迟。实现基于 CNN 检测器的端到端目标检测的另一条途径是 Learnable NMS 和关系网络, 它们展示了用于检测器的另一个网络, 用于去除重复预测。OneNet 和 DeFCN 提出了一对一匹配策略, 以实现完全卷积网络的端到端目标检测。FCOS 引入了一个正样本选择器, 用于选择预测的最优样本。

2.3 总而言之

然而, YOLOs 依赖非极大值抑制 (NMS) 进行后处理, 这限制了它们的端到端部署并影响了推理延迟。此外, YOLOs 的各个组件设计缺乏全面和彻底的检查, 导致计算冗余和模型能力的局限性。

3 YOLOv10 算法概述




图 2: (a) 为无 NMS 培训提供一致的双重任务。(b) 一对一的频率 YOLOv8-S 的一对多结果的前 1/5/10 中的分配，其中默认使用 $\alpha_{o2o} = 0.5$; $o2o = 6$ 。为了保持一致性， $\alpha_{o2o} = 0.5$; $o2o = 6$ 。对于不一致， $\alpha_{o2o} = 0.5$; $o2o = 2$

3.1 无需 NMS 的一致双重分配训练

在训练期间，YOLOs 通常利用 TAL 为每个实例分配多个正样本。采用一对多分配可以产生丰富的监督信号，有助于优化并实现卓越的性能。然而，这种方法需要 YOLOs 在推理过程中依赖 NMS 后处理，这导致了次优的推理效率。虽然先前的工作探索了一对一匹配来抑制多余的预测，但它们通常会引入额外的推理开销或导致次优性能。在这项工作中，我们提出了一种无需 NMS 的 YOLO 训练策略，通过双重标签分配和一致的匹配度量，实现了高效率和有竞争力的性能。

3.1.1 双重标签分配

与一对多分配不同，一对一匹配为每个真实标注只分配一个预测，避免了 NMS 后处理。然而，这导致监督信号变弱，引起次优的准确性和收敛速度。幸运的是，这种缺陷可以通过一对多分配来补偿。为了实现这一点，我们为 YOLOs 引入了双重标签分配，结合了两种策略的优势。具体来说，如图 2 所示，我们为 YOLOs 增加了另一个一对一的头部。它保持与原始一对多分支相同的结构，并采用相同的优化目标，但利用一对一匹配来获取标签分配。在训练期间，两个头部与模型一起优化，允许 backbone 和 neck 享受由一对多分配提供的丰富监督。在推理期间，我们丢弃一对多头部，并使用一对一头部进行预测。这使得 YOLOs 能够实现无需任何额外推理成本的端到端部署。此外，在一对一匹配中，我们采用顶部选择，以较少的额外训练时间实现了与匈牙利匹配相同的性能。

一致匹配度量。在分配过程中，一对一和一对多方法都利用一个度量标准来量化预测和实例之间的一致性水平。为了实现两个分支的预测感知匹配，我们采用了统一的匹

配度量, 即 匹配度量: $m(\alpha, \beta) = s \cdot p^\alpha \cdot \text{IoU}(\hat{b}, b)^\beta$, 其中 p 是分类得分, $\hat{b}$ 和 b 分别表示预测和实例的边界框。 s 表示空间先验, 指示预测的锚点是否在实例内。 α 和 β 是两个重要的超参数, 平衡语义预测任务和位置回归任务的影响。 我们将一对多和一对一度量分别表示为 一对多匹配度量: $m_{o2m} = m(\alpha_{o2m}, \beta_{o2m})$ 和 一对一匹配度量: $m_{o2o} = m(\alpha_{o2o}, \beta_{o2o})$ 。 这些度量影响两个头部的标签分配和监督信息。

在双重标签分配中, 一对多分支比一对一分支提供了更丰富的监督信号。 直观地说, 如果我们能够使一对一头部的监督与一对多头部的监督协调一致, 我们就可以朝着一对多头部优化的方向优化一对一头部。 结果, 一对一头部在推理期间可以提供更高质量的样本, 从而带来更好的性能。 为此, 我们首先分析两个头部之间的监督差距。 由于训练过程中的随机性, 我们从两个头部以相同的初始值开始检查, 并产生相同的预测, 即一对一头部和一对多头部为每个预测-实例对生成相同的 p 和 IoU 。 我们注意到两个分支的回归目标没有冲突, 因为匹配的预测共享相同的目标, 而不匹配的预测则被忽略。 监督差距因此在不同的分类目标中。 给定一个实例, 我们将其与预测的最大 IoU 表示为 u^* , 以及一对多和一对一匹配的最大得分分别为 m_{o2m}^* 和 m_{o2o}^* 。 假设一对多分支产生了正样本集合 Ω , 并且一对一分支根据度量 $m_{o2o,i} = m_{o2o}^*$ 选择第 i 个预测, 则我们可以推导出对于 $j \in \Omega$ 的分类目标 $t_{o2m,j} = u^* \cdot \frac{m_{o2m,j}}{m_{o2m}^*} u^*$, 以及 $t_{o2o,i} = u^* \cdot \frac{m_{o2o,i}}{m_{o2o}^*} = u^*$ 。 对于任务对齐损失, 如中所述。 因此, 两个分支之间的监督差距可以通过不同分类目标的 1-Wasserstein 距离推导出来, 即

$$\text{监督差距: } A = |t_{o2o,i} - I(i \in \Omega)t_{o2m,i}| + \sum_{k \in \Omega \setminus \{i\}} |1 - (1 - t_{o2m,k})|$$

我们可以观察到, 随着 $t_{o2m,i}$ 的增加, 差距减少, 即 i 在 Ω 中的排名越高。 当 $t_{o2m,i} = u^*$ 时, 即 i 是 Ω 中最佳的正样本时, 它达到最小, 如图 2.(a) 2 所示。 为了实现这一点, 我们提出了一致匹配度量, 即 $\alpha_{o2o} = r \cdot \alpha_{o2m}$ 和 $\beta_{o2o} = r \cdot \beta_{o2m}$ 这意味着 $m_{o2o} = m_{o2m}^r$ 。 因此, 一对多头部的最佳正样本也是一对一头部的最佳样本。 结果, 两个头部可以被一致和协调地优化。 为了简化, 我们默认取 $r=1$, 即 $\alpha_{o2o} = \alpha_{o2m}$ 和 $\beta_{o2o} = \beta_{o2m}$ 。 为了验证改善的监督对齐, 我们统计了训练后在一对多结果的前 1/5/10 中一对一匹配对的数量。 如图 2.(b) 2 所示, 在一致匹配度量下, 对齐得到了改善。 有关数学证明的更全面理解, 请参阅附录。

3.2 全面的效率-准确性驱动的设计

除了后处理, YOLOs 的模型架构也对效率-准确性权衡构成巨大挑战尽管先前的工作探索了各种设计策略, 但对 YOLOs 的各个组件进行全面检查仍然缺乏。 结果, 模型架构表现出不可忽视的计算冗余和受限的能力, 这阻碍了其实现高效率和性能的潜力。 在这里, 我们旨在从效率和准确性两个角度全面地对 YOLOs 进行模型设计。

3.2.1 效率驱动的设计

YOLO 的组件包括 stem、下采样层、具有基本构建块的阶段和头部。stem 的计算成本较低，因此我们对其他三个部分执行效率驱动的设计。

1. 轻量级分类头部。分类和回归头部在 YOLOs 中通常具有相同的架构。然而，它们在计算消耗上表现出显著的差异。例如，在 YOLOv8-S 中，分类头部 (5.95G/1.51M) 的 FLOPs 和参数计数分别是回归头部 (2.34G/0.64M) 的 2.5 倍和 2.4 倍。然而，在分析分类误差和回归误差的影响后，我们发现回归头部对 YOLOs 的性能更为重要。因此，我们可以在不担心大幅损害性能的情况下减少分类头部的开销。因此，我们为分类头部采用了一个轻量级架构，由两个深度可分离卷积组成，核大小为 3×3 ，后跟一个 1×1 卷积。

2. 空间-通道解耦下采样。YOLOs 通常利用常规的 3×3 标准卷积，步长为 2，同时实现空间下采样（从 $H \times W$ 到 $H^2 \times W^2$ ）和通道变换（从 C 到 $2C$ ）。这引入了不可忽视的计算成本 $O(9^2 HWC^2)$ 和参数计数 $O(18C^2)$ 。相反，我们提议将空间缩减和通道增加操作解耦，实现更高效的下采样。具体来说，我们首先利用点卷积来调节通道维度，然后使用深度卷积来执行空间下采样。这将计算成本降低到 $O(2HWC^2 + 9^2 HWC)$ ，参数计数降低到 $O(2C^2 + 18C)$ 。同时，它最大化了下采样期间的信息保留，带来了在延迟减少的情况下具有竞争力的性能。

3. 基于秩的块设计。YOLOs 通常对所有阶段使用相同的基本构建块，例如 YOLOv8 中的瓶颈块。为了彻底检查 YOLOs 的这种同质设计，我们使用内在秩来分析每个阶段的冗余。具体来说，我们计算每个阶段最后一个基本块中最后一个卷积的数值秩，它统计大于阈值的奇异值的数量。图 3.(a) 3 展示了 YOLOv8 的结果，表明深层阶段和大型模型更容易表现出更多的冗余。这一观察表明，简单地将相同的块设计应用于所有阶段对于最佳容量-效率权衡来说是次优的。为了解决这个问题，我们提出了一个基于秩的块设计方案，旨在使用紧凑的架构设计降低显示出冗余的阶段的复杂性。我们首先提出了一个紧凑的倒置块 (CIB) 结构，它采用成本低廉的深度卷积用于空间混合和成本效益高的点卷积用于通道混合，如图 3.(b) 3 所示。它可以作为高效的基本构建块，例如嵌入到 ELAN 结构中（图 3.(b) 3）。然后，我们提倡一个基于秩的块分配策略，在保持竞争力的同时实现最佳效率。具体来说，给定一个模型，我们根据它们的内在秩按升序对它的所有阶段进行排序。我们进一步检查将领先阶段中的基本块替换为 CIB 的性能变化。如果没有与给定模型相比的性能下降，我们继续替换下一个阶段，并在否则停止该过程。因此，我们可以在阶段和模型尺度上实施自适应紧凑块设计，实现更高效率而不影响性能。由于篇幅限制，我们在附录中提供了算法的详细信息。

3.2.2 准确性驱动的设计

我们进一步探索了大核心卷积和自注意力，以准确性为驱动的设计，旨在最小成本下提升性能。

1. 大核心卷积。利用大核心深度卷积是扩大感知场并增强模型能力的有效方法。然而，简单地在所有阶段使用它们可能会引入浅层特征的污染，这些特征用于检测小物体，同时也会引入高分辨率阶段的显著 I/O 开销和延迟。因此，我们提议在深层阶段的 CIB 内使用大核心深度卷积。具体来说，我们将 CIB 中第二个 3×3 深度卷积的核心大小增加到 7×7 ，遵循。此外，我们采用结构重参数化技术 [10, 9, 53]，引入另一个 3×3 深度卷积分支，以减轻优化问题而不增加推理开销。此外，随着模型大小的增加，其感知场自然扩展，使用大核心卷积的好处减少。因此，我们仅对小模型尺度采用大核心卷积。

2. 部分自注意力 (PSA)。由于其显著的全局建模能力，自注意力被广泛用于各种视觉任务。然而，它表现出高计算复杂性和内存占用。为了解决这个问题，鉴于普遍存在的注意力头冗余，我们提出了一个高效的部分自注意力 (PSA) 模块设计，如图 3.(c) 3 所示。具体来说，我们在 1×1 卷积后将特征均匀地跨通道分成两部分。我们只将一部分输入由多头自注意力模块 (MHSA) 和前馈网络 (FFN) 组成的 NPSA 块。然后将两部分连接并通过 1×1 卷积融合。此外，我们遵循将 MHSA 中的查询和键的维度设置为值的一半，并用 BatchNorm 替换 LayerNorm 以实现快速推理。此外，PSA 仅放置在具有最低分辨率的第 4 阶段之后，避免了自注意力的二次计算复杂性带来的过度开销。通过这种方式，全局表示学习能力可以以低成本纳入 YOLOs，这很好地增强了模型的能力和改进了性能。




图 3: (a) YOLOv8 中跨阶段和模型的内在排名。骨干和颈部的阶段按模型前向过程的顺序编号。数值秩 r 被归一化对于 y 轴，其阈值设置为 $\lambda_{max}/2$ ，默认情况下，其中 C_o 表示输出通道和 λ_{max} 是最大的奇异值。可以观察到，深阶段和大模型表现出较低的内在排名值。(b) 紧凑倒置块 (CIB)。(c) 部分自我注意模块 (PSA)。

4 实验

4.1 实现细节

我们选择 YOLOv8 作为我们的基线模型，由于其在延迟和准确性之间取得了值得称赞的平衡，并且它在各种模型尺寸上都有可用性。我们采用一致的双重分配进行无需 NMS 的训练，并基于此进行全面的效率-准确性驱动的设计，带来了我们的 YOLOv10 模型。YOLOv10 拥有与 YOLOv8 相同的变体，即 N / S / M / L / X。此外，我们通过简单地增加 YOLOv10-M 的宽度比例因子，派生出一个新的变体 YOLOv10-B。我们在 COCO[33] 上验证了所提出的检测器在相同的从头开始训练设置下 [20, 59, 56]。此外，所有模型的延迟在 T4 GPU 上使用 TensorRT FP16 进行了测试，遵循 [71]。

4.2 与最先进模型的比较

如表 1 所示，我们的 YOLOv10 在不同模型尺度上实现了最先进的性能和端到端延迟。我们首先将 YOLOv10 与我们的基线模型进行比较，即 YOLOv8。在 N / S / M / L / X 五个变体上，我们的 YOLOv10 实现了 1.2%/1.4%/0.5%/0.3%/0.5% AP (平均精度) 提升，同时参数数量减少了 28%/36%/41%/44%/57%，计算量减少了 23%/24%/25%/27%/38%，延迟降低了 70%/65%/50%/41%/37%。与其他 YOLOs 相比，YOLOv10 在准确性和计算成本之间也展现出了优越的权衡。具体来说，对于轻量级和小模型，YOLOv10-N / S 的性能超过了 YOLOv6-3.0-N / S 1.5 AP，并且参数数量和计算量分别减少了 51%/61% 和 41%/52%。对于中等模型，与 YOLOv9-C / YOLO-MS 相比，YOLOv10-B / M 在相同或更好的性能下分别实现了 46%/62% 的延迟降低。对于大型模型，与 Gold-YOLO-L 相比，我们的 YOLOv10-L 参数数量减少了 68%，延迟降低了 32%，并且 AP 显著提高了 1.4%。此外，与 RT-DETR 相比，YOLOv10 在性能和延迟方面都取得了显著的改进。值得注意的是，YOLOv10-S / X 在相似性能下的推理速度分别比 RT-DETR-R18 / R101 快 1.8 倍和 1.3 倍。这些结果很好地展示了 YOLOv10 作为实时端到端检测器的优越性。

我们还比较了使用原始一对多训练方法的其他 YOLOs。在这种情况下，我们考虑了模型前向过程的性能和延迟 (Latency)，遵循国际条例。如表 1 所示，YOLOv10 在不同模型尺度上也展现出了最先进的性能和效率，这表明了我们架构设计的有效性。

4.3 模型分析

消融研究。我们在表 2 中展示了基于 YOLOv10-S 和 YOLOv10-M 的消融结果。可以观察到，我们无需 NMS 的一致双重分配显著降低了 YOLOv10-S 的端到端延迟 4.63ms，同时保持了 44.3% AP 的有竞争力的性能。此外，我们的效率驱动的设计导致了 11.8 M 参数和 20.8 GFLOPs 的减少，对 YOLOv10-M 的延迟有相当大的降低 0.65ms，很好地展示了其有效性。此外，我们的准确性驱动的设计为 YOLOv10-S

和 YOLOv10-M 分别实现了 1.8 AP 和 0.7 AP 的显著改进，并且仅有 0.18ms 和 0.17ms 的延迟开销，很好地展示了其优越性。

5 结论

在本文中，我们针对 YOLOs 的整个检测流程，包括后处理和模型架构。对于后处理，我们提出了一致的双重分配策略，实现了无需 NMS 的高效端到端检测。对于模型架构，我们引入了全面的效率-准确性驱动的设计策略，改善了性能-效率权衡。这些带来了我们的 YOLOv10，一个新的实时端到端目标检测器。广泛的实验表明，与其它先进的检测器相比，YOLOv10 实现了最先进的性能和延迟，很好地证明了其优越性。
[1]

总结

实时目标检测以 YOLO 系列为主导，以往的系列中后端需要用到 NMS 处理，在效率和准确性两个角度仍有提升空间。在 YOLO10 中，作者引入了轻量级分类头部、空间-通道解耦下采样、基于秩的块设计、大核心卷积、部分自注意力 (PSA) 等创新模块，成功提升了效率，和准确性，证明了 YOLOv10 作为端到端的实施目标检测器的优越性。

参考文献

- [1] A. W. H. L. K. Z. J. H. G. Ding*, “Yolov10: Real-time end-to-end object detection,” <https://arxiv.org/pdf/2405.14458>, accessed 20240610.