

具身智能：从分层小模型到端到端大模型的范式跃迁

——具身智能相关论文读书笔记

李佩优 PB23000270

2025 年 8 月 11 日

1 摘要

本文综述了具身智能（Embodied AI）从分层模型向端到端大模型的关键范式跃迁。文章系统探讨了多样具身载体（如各类机器人形态）及其特性，并强调了高保真仿真平台在解决真实训练数据稀缺和成本问题中的核心作用。核心聚焦于具身智能体的构建：介绍了多模态基础模型（如 RT 系列、PaLM-E）通过功能集成（VLA 模型）、大规模数据（如 Open X-Embodiment）和效率优化的演进；阐述了利用大语言模型（LLM）进行任务分解与规划以及动作执行（调用 API 或端到端模型）的策略；并重点分析了仿真到现实（Sim-to-Real）适应的核心挑战与方案（包括世界模型构建、数据策略如 Domain Randomization）。最后，概述了前沿进展（如物理级 VLN 平台、手术机器人自主操作等）及计算机图形学在高保真仿真、物理引擎和 3D 重建中的关键支撑作用。结论指出，端到端大模型、强大仿真与图形学技术的融合，正推动具身智能在复杂物理环境中的感知、决策与行动能力发展，为人机无缝协作奠定基础。

2 前言

具身智能（Embodied AI）作为人工智能与机器人学的交叉领域，旨在为智能体赋予在物理环境中感知、决策和行动的能力。近年来，该领域在仿真平台、三维空间重建、自主操作和记忆架构等方面取得突破性进展，而计算机图形学通过高保真仿真、物理引擎和实时渲染等技术，为具身智能提供了关键的训练与验证基础。

3 介绍

具身人工智能最初是由艾伦·图灵（Alan Turing）于 1950 年根据具身图灵测试提出的[?], 其核心思想是：真正的智能体不仅能在虚拟空间中处理抽象问题，还必须能在复杂多变的物理世界中生存与交互。网络空间中的智能体通常被称为离身人工智能（disembodied intelligence），而物理空间中的智能体则被称为具身人工智能。与传统的”离身 AI”（如 ChatGPT）相比，具身 AI 强调“体一智”融合，即将认知能力嵌入物理实体之中，如机器人、汽车、可穿戴设备等。

具身智能是通过考虑智能体与其环境之间的严格耦合，在智能体自身身体、知觉和运动系统以及大脑的约束下，设计和理解具身智能体智能体智能行为的计算方法。[?] 具体而言，具身智能被视为形态、行动、感知和学习的协同作用 (morphology, action, perception, and learning)。[?]

4 具身机器人

具身智能体能够主动与物理环境进行交互，涵盖多种具体形态，包括机器人、智能家电、智能眼镜、自动驾驶车辆等。其中，机器人作为最具代表性的形态尤为突出。根据应用场景需求，机器人被设计成不同形态以充分发挥其硬件特性完成特定任务，如图 1 所示。




图 1: 具身机器人包括固定底座机器人、四足机器人、人形机器人、轮式机器人、履带式机器人和仿生机器人。

固定基座机器人, 如 (a) 所示: 结构紧凑、精度高, 适用于实验室、教育、工业制造。优点: 稳定、高精度、可编程性强。缺点: 工作范围受限, 灵活性差。实际应用中可以与灵巧手机械爪等终端配合使用以改善灵活性差的问题。

如 Franka (Franka Emika panda)[?], Kuka iiwa (KUKA)[?] 和 Sawyer (Rethink Robotics)[?] 等, 适用于高精度工业操作, 但受限于固定位置。

轮式与履带式机器人, 如 (b)(c) 所示:

轮式机器人: 移动高效, 结构简单、成本较低, 适合平坦地面 (物流、仓储、安检)。优点: 能效高、速度快。缺点: 复杂地形适应能力差, 负载和机动性有限。

履带机器人: 越野能力强, 适合复杂地形 (农业、建筑、救灾、军事)。优点: 接地面积大、不易下陷、稳定性好。缺点: 能效低、平地速度慢、灵活性较差。

轮式机器人例如 Kiva 机器人 (Kiva Systems) [?] 和 Jackal 机器人 (Clearpath Robotics)

[?] 适用于平坦地面，而履带式机器人如 PackBot[?] 则适用于复杂地形。

四足机器人, 如 (d) 所示: 仿生设计, 稳定性与适应性好, 适合复杂地形探索 (搜救、军事、巡检)。优点: 地形适应性强、机动灵活。缺点: 设计复杂、成本高昂、续航时间短。

几种四足机器人被广泛应用: 宇树机器人 (Unitree Robotics)、波士顿动力 Spot (Boston Dynamics Spot) 和 ANYmal C (ANYbotics)。

宇树机器人的 Unitree A1 和 Go1 以其成本效益和灵活性著称。A1 [?] 和 Go1 [?] 具备强大的移动性和智能避障能力, 适用于多种应用场景。

波士顿动力的 Spot 以其卓越的稳定性和操作灵活性闻名, 常用于工业巡检和救援任务。它具有强大的负载能力和适应性, 能够在恶劣环境中执行复杂任务 [?]

ANYbotics 的 ANYmal C 凭借其模块化设计和高耐用性, 被广泛应用于工业检查和维护。ANYmal C 具备自主导航和远程操作能力, 适合长时间的户外任务, 甚至极端的月球任务 [?]

人形机器人, 如 (e) 所示: 人形外观, 模仿人类动作, 适用于服务业、医疗、人机协作。优点: 灵巧手部可执行精细任务。缺点: 控制系统复杂, 稳定性挑战大, 传统液压系统笨重昂贵 (新趋势为电机驱动 + 大语言模型 LLMs)。

在现有人形机器人中,

Atlas (波士顿动力) 以其卓越的机动性和稳定性闻名。Atlas 能够完成奔跑、跳跃和翻滚等复杂的动态动作, 展示了人形机器人在高动态环境中的潜力 [?]

HRP 系列 (AIST) 被用于各种研究和工业应用, 其设计注重高稳定性和灵活性, 使其在复杂环境中 (尤其是与人类协作的任务中) 表现有效 [?]

ASIMO (本田) 是最著名的人形机器人之一, 能够行走、奔跑、爬楼梯, 并能识别人脸和手势, 适合接待和引导服务 [?]

此外, 小型社交机器人 Pepper (软银机器人) 能够识别情绪并进行自然语言交流, 广泛

应用于客户服务和教育场景 [?]

仿生机器人, 如 (f) 所示: 模仿自然界生物形态和运动机制 (如鱼、昆虫、软体)。优点: 运动灵活、环境影响小、能效高。缺点: 设计制造复杂昂贵, 耐久性和可靠性在极端环境受限。

5 具身模拟器

数据稀缺一直是具身人工智能研究中持续存在的挑战。首先, 由于其实时性, 现实世界的机器人训练进展缓慢, 无法并行化。相关成本高得令人望而却步, 需要专门的部署站点、数据收集的专家作控制以及大量的硬件费用。此外, 最重大的挑战在于泛化性不足, 这源于机器人硬件配置、控制方法和实现框架的巨大差异, 阻碍了数据的可移植性。在这种情况下, 模拟器为收集和训练具身人工智能的数据提供了一种新颖的解决方案。

具身模拟器对具身智能至关重要: 它们能够以低成本进行实验, 通过模拟潜在危险场景保障安全; 支持在多样化环境中大规模测试, 实现快速原型设计; 让更多研究者都能使用; 提供可控环境以开展精确研究; 为训练与评测生成大量数据; 并给出统一基准, 方便算法比较。为了让智能体与环境交互, 必须构建逼真的仿真环境, 这就必须综合考虑环境的物理特性、物体的属性以及它们之间的相互作用。

模拟器分为基于底层仿真的通用模拟器和基于真实场景的仿真。

5.1 通用模拟器

物理世界交互与动态变化不可替代, 但在物理环境中部署具身模型成本高昂、挑战繁多。通用模拟器可在成本、时间与安全性上提供显著优势, 成为算法开发与模型训练的理想虚拟场所。

Isaac Sim

Isaac Sim [?] 是面向机器人与 AI 研究的高保真仿真平台，集成实时光追、丰富机器人模型库及深度学习支持，广泛用于自动驾驶、工业自动化与人机交互等场景。

Gazebo

Gazebo [?] 是开源机器人模拟器，拥有庞大机器人库并与 ROS 深度集成，支持多传感器仿真，常用于机器人导航控制及多机器人协同研究。

PyBullet

PyBullet [?] 是 Bullet 物理引擎的 Python 接口，易用且支持多样化传感器与深度学习，提供实时刚体动力学、碰撞检测与约束求解功能。

通用模拟器一览

表 1 汇总了 10 个通用模拟器的关键特性与应用场景；图 2 给出可视化示例，供研究者按需选用，加速具身智能研发。




图 2: 通用模拟器

Simulator	Year	HFPS	HQGR	RRL	DLS	LSPC	ROS	MSS	CP	Physics Engine	Main Applications
Isaac Sim [?]	2023	○	○	○	○	○	○	○	○	PhysX	Nav, AD
Isaac Gym [?]	2019		○		○	○				PhysX	RL, LSPS
Gazebo [?]	2004		○	○			○	○	○	ODE, Bullet, Simbody, DART	Nav, MR
PyBullet [?]	2017				○				○	Bullet	RL, RS
Webots [?]	1996		○	○				○	○	ODE	RS
MuJoCo [?]	2012	○			○				○	Custom	RL, RS
Unity ML-Agents [?]	2017		○		○				○	Custom	RL, RS
AirSim [?]	2017		○						○	Custom	Drone sim, AD, RL
MORSE [?]	2015							○	○	Bullet	Nav, MR
CoppeliaSim (V-REP) [?]	2013		○	○				○	○	Bullet, ODE, Vortex, Newton	MR, RS

表 1: general simulator. hfps: high-fidelity physical simulation; hqgr: high-quality graphics rendering; rrl: rich robot library; dls: deep learning support; lspc: large-scale parallel computing; ros: tight integration with ros; mss: multiple sensor simulation; cp: cross-platform. nav: robot navigation; ad: auto driving; rl: reinforcement learning; lspc: large-scale parallel sim; mr: multi-robot systems; rs: robot simulation. ○ indicates that the simulator excels in this aspect.

5.2 基于真实场景的模拟器

实现通用家庭活动智能体是具身研究的核心目标之一。此类智能体需深入理解人类日常，在室内完成导航与交互等复杂任务。为此，模拟环境须逼近真实世界，催生了依托真实数据、由 UE5/Unity 构建的逼真 3D 场景模拟器。

AI2-THOR

AI2-THOR [?] 是 AllenAI 基于 Unity3D 开发的高保真室内模拟器，拥有 2000+ 可交互对象，支持冷热、开关等物理属性。其 iTHOR 含 120 个房间，RoboTHOR 含 89 个与现实公寓一一对应的模块化场景，已支撑百余篇研究。

Matterport3D

Matterport3D [?] 源于 R2R [?]，包含 90 个建筑、194 400 张 RGB-D 图像，提供表面重建与语义分割注释。场景被离散为“视点”，智能体在相邻视点间移动并获取 1280×1024 全景图，成为具身导航重要基准。

VirtualHome

VirtualHome [?] 以环境图表示对象及其关系，支持用户自定义场景配置。其 API 将动作简化为“操作 + 对象”，便于指令分解与具身规划研究。

Habitat

Habitat [?] 是 Meta 开源的大规模交互模拟器，基于 Bullet 实现高性能并行 3D 仿真，支持自定义场景、多智能体与多传感器，为人类-机器人协作研究提供丰富接口。

SAPIEN：以交互为核心的模拟器

SAPIEN [?] 与其他侧重场景的模拟器不同，它将重点放在对象交互上。基于 PhysX 物理引擎，SAPIEN 支持通过 ROS 接口实现基于力/力矩的精细关节控制。借助 PartNet-Mobility 数据集，SAPIEN 提供大量可交互室内对象，并允许用户导入自定义资源。与 AI2-THOR 等直接修改对象状态的脚本式模拟器相比，SAPIEN 强调物理交互：具身智能体可通过真实力控方式操作门、抽屉等带关节部件，从而自然改变对象状态。这些特性使其成为训练精细物体操作任务的理想平台。

iGibson：面向对象的斯坦福开源模拟器

iGibson [?, ?] 由斯坦福大学开源，基于 Bullet 物理引擎构建，内置 15 个高质量室内场景，并支持导入 Gibson 与 Matterport3D 等资源。作为面向对象的模拟器，iGibson 为对象赋予丰富的可变属性，不仅包括姿态、速度等运动学量，还涵盖温度、湿度、洁净度、开关状态等。除常规 RGB-D 与语义传感器外，iGibson 额外提供 LiDAR，便于智能体获取 3D 点云。其支持连续动作控制与精细关节控制，使具身智能体在自由移动的同时可与对象进行细腻交互。

TDW: MIT 的多模态高保真模拟器

TDW [?] 由 MIT 推出，是较新的具身模拟平台。它融合高保真视觉渲染、真实物理效果及情境音频，通过单一灵活控制器实现感知与交互的统一。TDW 集成多种物理引擎，可模拟刚体、软体、织物及流体等不同材质，并在交互时产生真实声音，相较其他模拟器迈出重要一步。平台支持多智能体部署，并提供丰富 API 与资产库，用户可自由定制室内外场景与任务，满足多样化研究需求。

自动化场景构建：从数据到任务

高质量具身数据的获取离不开自动化场景构建。**RoboGen** [?] 通过大语言模型从随机 3D 资产中采样并定制任务，再自动训练智能体；**HOLODECK** [?] 可按人类指令在 AI2-THOR 中自动生成对应场景；**PhyScene** [?] 基于条件扩散生成物理一致且可交互的 3D 场景；艾伦人工智能研究所进一步推出 **ProcTHOR** [?]，可批量生成具备交互性、多样性与合理性的虚拟环境。这些自动化方法为具身智能研究提供了持续、可扩展的数据与任务来源。

表 2 汇总了上述基于真实场景的模拟器。




图 3: 物理模拟器

具身智能的任务被大致划分为三层，感知，决策以及控制。

Simulation Platform	Year	Num of Scenes	Cont.	Action 3D Scans	Sensors	Physics	Multi-Agent	Obj. States	3D Assets
AI2-THOR [?]	2017	120	✓	×	RGB-D, S	✓	✓	✓	✓
Matterport 3D [?]	2018	90	×	✓	RGB-D, S	×	×	×	×
Habitat [?]	2019	1000+	✓	✓	RGB-D, S	✓	✓	×	✓
Virtual Home [?]	2018	50	×	×	RGB-D, S	✓	✓	✓	✓
SAPIEN [?]	2020	46	✓	×	RGB-D, S	✓	×	✓	✓
iGibson [?, ?]	2021	15	✓	✓	RGB-D, S, L	✓	×	✓	✓
TDW [?]	2021	–	✓	✓	RGB-D, S, A	✓	✓	✓	✓

表 2: Comparison of Real-Scene Based Simulators. For the sensor, S refers to Semantic, L refers to LiDAR and A refers to Audio.

6 具身感知

6.1 主动视觉感知

主动视觉感知（Active Visual Perception）是实现具身智能（Embodied AI）在视觉推理与社会智能等核心目标上的关键技术，其体系由三大基础支柱协同构成：视觉同时定位与建图（vSLAM）、3D 场景理解（3D Scene Understanding）、主动探索（Active Exploration）。

1. 视觉同时定位与建图 (vSLAM) 视觉同时定位与建图 (Visual Simultaneous Localisation and Mapping) 同时定位与建图 (SLAM) 是一种在未知环境中确定移动机器人位置并同时构建该环境地图的技术 [121, 122]。基于测距的 SLAM [123, 124, 125] 使用测距仪（例如，激光扫描仪、雷达和/或声纳）创建点云表示，但成本高昂且提供的环境信息有限。视觉 SLAM (vSLAM) [118, 119] 使用机载相机捕获帧并构建环境表示。由于其硬件成本低、在小规模场景中精度高以及能够捕获丰富的环境信息而广受欢迎。经典的 vSLAM 技术可分为传统 vSLAM 和语义 vSLAM [119]。

传统 vSLAM 系统利用图像信息和多视图几何原理估计机器人在未知环境中的位姿，构建由点云组成的低级地图（例如，稀疏地图、半稠密地图和稠密地图），例如基于滤波器的方法（如 MonoSLAM [75], MSCKF [76]）、基于关键帧的方法（如 PTAM [77], ORB-SLAM

[78]) 和直接跟踪方法 (如 DTAM [79], LSD-SLAM [80])。由于低级地图中的点云并不直接对应于环境中的物体, 使得具身机器人难以解释和利用。然而, 语义概念的出现, 特别是集成了语义信息解决方案的语义 vSLAM 系统, 显著提高了机器人感知和导航未知环境的能力。

早期的工作, 如 SLAM++[81], 使用实时 3D 物体识别和跟踪来创建高效的物体图, 实现了在杂乱环境中的鲁棒闭环检测、重定位和物体检测。CubeSLAM[82] 和 HDP-SLAM[83] 将 3D 矩形引入地图以构建轻量级语义地图。QuadricSLAM[84] 采用语义 3D 椭球体在复杂几何环境中实现对物体形状和位姿的精确建模。So-SLAM[85] 在室内环境中融入了全耦合的空间结构约束 (共面性、共线性和邻近性)。为应对动态环境的挑战, DS-SLAM[86]、DynaSLAM[87] 和 SG-SLAM[88] 利用语义分割进行运动一致性检查, 并采用多视图几何算法来识别和过滤动态物体, 确保稳定的定位和建图。OVD-SLAM[89] 利用语义、深度和光流信息来区分动态区域, 而无需预定义标签, 实现了更准确和鲁棒的定位。GS-SLAM[90] 利用 3D 高斯表示, 通过实时可微分的泼溅渲染流水线和自适应扩展策略, 在效率和精度之间取得平衡。

- **目标:** 在未知环境中实时确定机器人自身位置 (定位) 并构建环境地图 (建图)。
- **演进:** 由基于点云的低级地图 (如 ORB-SLAM) 演进至语义 vSLAM (SLAM++、CubeSLAM、QuadricSLAM、DynaSLAM、GS-SLAM)。通过引入物体级语义信息 (物体识别、形状建模) 及动态环境处理 (过滤动态物体), 显著提升了地图的可解释性与实用性, 使机器人能够更好地理解和利用环境。

2. 3D 场景理解 (3D Scene Understanding) 3D 场景理解旨在区分物体的语义、识别其位置, 并从 3D 场景数据中推断其几何属性, 这在自动驾驶 [126]、机器人导航 [127] 和人机交互 [128] 等领域至关重要。场景可以使用 LiDAR 或 RGB-D 传感器等 3D 扫描工具记录为 3D 点云。与图像不同, 点云是稀疏、无序且不规则的 [120], 这使得场景解释极具挑战性。

近年来,提出了许多用于 3D 场景理解的深度学习方法,可分为基于投影的方法、基于体素的方法和基于点的方法。具体来说,基于投影的方法(如 MV3D[91]、PointPillars[92]、MVCNN[93])将 3D 点投影到各种图像平面上,并采用基于 2D CNN 的主干网络进行特征提取。基于体素的方法将点云转换为规则的体素网格,以促进 3D 卷积操作(如 VoxNet[94]、SSCNet[95]),一些工作通过稀疏卷积提高了效率(如 MinkowskiNet[96]、SSCNet[97]、Embodiedscan[98])。相比之下,基于点的方法直接处理点云(如 PointNet[99]、PointNet++[100]、PointMLP[101])。最近,为了实现模型的可扩展性,出现了基于 Transformer 的架构(如 PointTransformer[102]、Swin3d[103]、PT2[104]、PT3[105]、3D-VisTA[106]、LEO[107]、PQ3D[108])和基于 Mamba 的架构(如 PointMamba[109]、PCM[110]、Mamba3D[111])。值得注意的是,除了直接使用点云特征外,PQ3D[108] 还无缝结合了多视图图像和体素的特征,以增强场景理解能力。

- **目标:** 从 3D 点云中解析场景,识别物体的语义、位置与几何属性。
- **方法分类:**
 - **基于投影:** 将 3D 点投影至 2D 平面后使用 CNN 处理(如 PointPillars)。
 - **基于体素:** 将点云转换为规则网格进行 3D 卷积,常用稀疏卷积提高效率(如 MinkowskiNet)。
 - **基于点:** 直接处理原始点云(如 PointNet++)。
- **前沿:** 采用 Transformer (PointTransformer、3D-VisTA) 与 Mamba (PointMamba) 架构提升性能与可扩展性,并探索多模态融合(图像 + 点云 + 体素,如 PQ3D)以增强理解能力。

3. 主动探索 (Active Exploration) 前面介绍的 3D 场景理解方法赋予机器人以被动方式感知环境的能力。在这种情况下,感知系统的信息获取和决策不会适应不断演变的场景。然

而，被动感知是主动探索的重要基础。鉴于机器人能够移动并频繁与其周围环境交互，它们也应该能够主动探索和感知其环境。它们之间的关系如图 7 所示。当前解决主动感知的方法侧重于与环境交互 [112, 113] 或通过改变视向以获得更多视觉信息 [114, 115, 116, 117]。

例如，Pinto 等人 [112] 提出了一个好奇的机器人，它通过与环境的物理交互来学习视觉表示，而不是仅仅依赖数据集中的类别标签。为了解决不同形态机器人之间交互式物体感知的挑战，Tatiya 等人 [113] 提出了一个多阶段投影框架，通过习得的探索性交互传递隐式知识，使机器人能够有效识别物体属性而无需从头开始重新学习。认识到自主捕获信息丰富观测的挑战，Jayaraman 等人 [114] 提出了一种强化学习方法，其中智能体通过减少其对环境未观察部分的不确定性，学习主动获取信息丰富的视觉观测，使用循环神经网络主动完成全景场景和 3D 物体形状。NeU-NBV[115] 引入了一个无地图规划框架，该框架迭代地定位 RGB 相机以捕获未知场景最具信息量的图像，利用基于图像的神经渲染中的新颖不确定性估计来引导数据收集朝向最不确定的视角。Hu 等人 [116] 开发了一种机器人探索算法，该算法使用状态价值函数预测未来状态的价值，结合了离线蒙特卡洛训练、在线时间差分适应以及基于传感器信息覆盖度的内在奖励函数。为了解决开放世界环境中的意外输入问题，Fan 等人 [117] 将主动识别视为一个顺序证据收集过程，在证据组合理论下提供逐步的不确定性量化和可靠预测，同时通过专门开发的奖励函数有效表征开放世界环境中行动的优点。

- **目标：**超越被动感知，使机器人通过主动行动（移动、交互、调整视角）获取更优、更全面的环境信息，以减少不确定性。
- **核心思想：**被动感知（vSLAM 与 3D 理解）是基础，主动探索赋予系统“主动性”。
- **主要策略：**
 - **物理交互驱动：**通过与物体/环境交互学习（如“好奇机器人”）。
 - **视角优化驱动：**选择信息量最大的下一个观测位置或方向（视向）以减少不确定

性（如 NeU-NBV、Jayaraman 的方法）。

- **算法支撑：**强化学习、不确定性估计及专门设计的奖励函数（覆盖度、信息增益、证据积累）用于指导探索决策（如 Hu、Fan 的方法）。

三者关系 vSLAM 提供定位与环境几何结构；3D 场景理解在 vSLAM 提供的地图/点云基础上赋予语义与物体级信息；主动探索利用前两者信息主动规划行动（移动、交互、调整视角）以获取更优信息，反过来更新并优化 vSLAM 地图与场景理解结果。如图 7 所示，三者相辅相成，共同构成完整的主动视觉感知系统，使机器人能够在复杂动态环境中智能地感知、理解与行动。

综上所述，实现具身智能所需之深度环境理解与交互能力，依赖于由 vSLAM（定位建图）、3D 场景理解（语义解析）与主动探索（信息获取优化）三大关键技术紧密协同构成的主动视觉感知系统。

6.2 3D 视觉定位

与传统局限于平面图像的 2D 视觉定位（Visual Grounding, VG）不同，3D 视觉定位（3D VG）引入了深度、透视以及物体间的空间关系，为智能体与环境交互提供了更鲁棒的框架。3D VG 的任务是利用自然语言描述在 3D 环境中定位物体 [?, ?]。如图 ?? 所示，近期的 3D VG 方法大致可分为两类：两阶段（two-stage）方法与一阶段（one-stage）方法 [?]

6.2.1 两阶段 3D 视觉定位方法

与 2D 任务类似，早期研究普遍采用“先检测后匹配”（detect-then-match）流程：首先由预训练检测器 [?] 或分割器 [?, ?, ?] 生成大量物体候选框，随后将候选框特征与语言查询特征融合以完成匹配。研究重点集中在第二阶段，即探索候选框特征与文本嵌入的相关性。ReferIt3D [?] 与 TGNN [?] 在匹配过程中引入图神经网络（GNN）以编码物体间上下

文。FFL-3DOG [?] 进一步利用语言场景图、多级 3D 候选关系图以及描述引导的 3D 视觉图增强自由形式描述下的鲁棒性。

近年来, Transformer 架构在 NLP 与 CV 任务中表现卓越, 3D VG 领域亦广泛采用其进行视觉-语言特征提取与融合。LanguageRefer [?] 通过 3D 空间嵌入、语言描述与类别标签嵌入实现鲁棒定位; 3DVG-Transformer [?] 提出坐标引导上下文聚合与多路注意力模块, 实现关系增强的候选框生成与跨模态消歧; TransRefer3D [?] 利用实体与关系感知注意力增强跨模态特征; GPS [?] 基于百万级 3D 视觉-语言数据集 SCENEVERSE, 采用三级对比对齐与掩码语言建模蒸馏知识; MVT [?] 提出多视图 Transformer, 学习视角无关的多模态表征; SAT [?] 与 LAR [?] 则引入 2D 图像特征以缓解点云稀疏、噪声等问题。

然而, 两阶段方法面临候选框数量困境: 稀疏候选框可能漏检目标, 稠密候选框又引入冗余, 增加匹配难度; 此外, 关键点采样策略与语言无关, 进一步降低检测器识别与语言相关候选框的能力。

6.2.2 一阶段 3D 视觉定位方法

一阶段方法在语言查询引导下联合完成物体检测与特征提取, 简化流程。

3D-SPS [?] 将任务视为关键点选择问题: 首先通过描述感知关键点采样粗筛语言相关点, 再经目标导向渐进挖掘精细定位。BUTD-DETR [?] 受 2D 预训练模型启发, 提出自底向上-自顶向下检测 Transformer, 结合框候选与语言描述实现 2D/3D VG 统一框架。EDA [?] 显式解耦文本为五类语义成分 (主体对象、辅助对象、属性、代词、关系), 并执行细粒度密集对齐。ReGround3D [?] 设计以视觉为中心的推理模块 (由多模态大模型驱动) 及链式定位机制, 交替进行推理与定位以精确获取物体位置。

6.3 视觉语言导航 (VLN)

视觉语言导航 (VLN) 是具身智能 (Embodied AI) 的核心研究问题, 旨在使智能体能够根据语言指令在未知环境中导航。VLN 要求机器人理解复杂多样的视觉观察, 并同时解析不同粒度的指令。

VLN 的输入通常包含两部分: **视觉信息** (当前观察 O 和历史信息 H) 和 **自然语言指令** (I)。智能体利用这些信息, 从候选动作中选择一个或一系列动作以满足指令要求, 该过程可表示为:

$$\text{动作} = \text{模型}(O, H, I) \quad (1)$$

常用评估指标包括:

- **SR (成功率)**: 反映导航性能。
- **TL (轨迹长度)**: 反映导航效率。
- **SPL (路径长度加权成功率)**: 综合反映整体性能。

下面从数据集和方法两方面介绍 VLN。

6.3.1 数据集 (Datasets)

VLN 数据集的指令形式 (如逐步动作描述、目标描述、模糊任务或人类需求) 和任务复杂度 (如简单导航、交互导航、序列任务导航) 各异, 带来了不同的挑战。主要数据集包括:

1. 室内场景导航:

- **R2R (Room to Room) [?]**: 基于 Matterport3D, 根据逐步指令在离散节点间导航。
- **R4R (Room-for-Room) [?]**: R2R 的扩展, 路径更长, 要求更强的长距离指令对齐能力。

- **VLN-CE** [?]: R2R/R4R 的连续环境扩展，智能体可自由移动，决策难度更大。
- **REVERIE** [?]: 基于 Matterport3D，要求根据简洁的高层指令定位远处不可见目标物体。
- **SOON** [?]: 提供从粗到细的长指令，导航过程目标导向且与初始位置无关。
- **DDN** [?]: 仅提供人类需求，智能体需在场景中寻找满足需求的对象。
- **ALFRED** [?]: 基于 AI2-THOR，需在交互环境中根据粗细粒度指令完成家务任务（包含导航与交互）。
- **OVM** [?]: 任务是在未知环境中拾取任意物体并放置到指定位置（仿真与实物框架）。
- **Behavior-1K** [?]: 基于 OmniGibson (iGibson 扩展)，包含 1000 个依赖技能的长序列复杂日常任务，涉及大量低级动作步骤，要求强大的理解和记忆能力。

2. 街景场景导航:

- **TOUCHDOWN** [?]: 基于谷歌街景，在纽约市街景模拟中导航寻找指定物体。

3. 对话辅助导航:

- **CVDN** [?]: 基于对话历史导航，可在不确定时提问求助。
- **DialFRED** [?]: ALFRED 的扩展，允许在导航交互过程中提问获取帮助。

6.3.2 方法 (Methods)

VLN 方法受大语言模型（LLMs）影响深远，主要分为三类：

1. **基于记忆理解 (Memory-Understanding Based)**: 关注环境感知理解和历史信息建模（过去学习），是主流方法。

- 图学习 (Graph-based Learning)

- LVERG [?]: 构建语言-视觉实体关系图建模模态间和视觉实体间关系。
- LM-Nav [?]: 构建导航图, 用 LLM 提取指令地标, 用 VLM 匹配图节点。

- 环境建图 (Environment Mapping)

- FILM [?]: 逐步构建 3D 体素语义地图。
- VER [?]: 通过 2D-3D 采样量化世界为结构化 3D 单元。

- 学习策略 (Learning Schemes)

- CMG [?]: 对抗学习结合模仿学习, 缩小训练-推理差距。
- GOAT [?]: 因果学习 (BACL/FACL) 结合对比学习, 充分利用信息。
- RCM [?]: 结合内外奖励进行跨模态对齐, 通过自监督模仿学习利用历史好决策。
- FSTT [?]: 引入测试时优化 (TTA) 提升性能。

- 大模型应用 (LLM Applications)

- NaviLLM [?]: 融合多模态信息输入 LLM 微调, 取得 SOTA。
- NaVid [?]: 改进历史信息编码, 不同程度保留历史与当前观察。
- DiscussNav [?]: 多角色 LLM 专家讨论决策, 零样本性能优异。

2. 基于未来预测 (Future-Prediction Based): 关注未来状态建模、预测和理解 (未来学习), 在连续环境与世界模型概念下日益受重视。

- 图学习与路径点预测 (Graph-based Learning & Waypoint Prediction)

- BGBL [?] / ETPNav [?]: 设计路径点预测器, 将连续导航迁移到离散节点导航。

- 未来环境预测 (Future Environment Prediction)

- **NvEM** [?]: 全局（主题模块）和局部（参考模块）融合编码邻域视图（理解未来观察）。
- **HNR** [?]: 用分层神经辐射场模型预测未来环境的特征表示（非像素级），构建可导航未来路径树。

- 强化学习 (Reinforcement Learning)

- **LookBY** [?]: 强化预测模块模仿世界模型预测未来状态和奖励。

- 大模型应用 (LLM Applications)

- **MiC** [?]: 要求 LLM 直接从指令预测目标及位置，通过场景感知描述提供导航指令（发挥“想象力”）。

3. 混合方法 (Hybrid Approaches): 结合过去学习与未来预测。

- **MCR-Agent** [?]: 三层策略（预测目标、预测交互目标掩码、学习历史决策）。
- **OVLm** [?]: 要求 LLM 预测操作和地标序列，持续更新视觉语言地图并链接操作与路径点。

6.4 非视觉感知

触觉传感器为智能体提供纹理、硬度、温度等高维细节，与视觉信息互补，显著提升机器人在高精度任务中的表现与人机交互体验 [?, ?, ?]。图 4 概括了主流传感器类型及数据形式，随后从估计、识别与操作三方面综述触觉感知任务。

6.4.1 传感器设计

触觉传感器按感知原理分为三类：




图 4: 触觉传感器分类。(a) 非视觉型: 力/压/振动/温度传感器; (b-e) 视觉型: 利用光学凝胶变形成像, 依次为 BioTac、GelSight、DIGIT、9DTact、Gelslim。

- **非视觉型:** 基于电/机械原理输出低维信号 (力、压、振动、温度), 代表为 BioTac 及其仿真器 [?, ?]。
- **视觉型:** 利用凝胶形变的光学成像, 代表有 GelSight [?], Gelslim [?], DIGIT [?], 9DTact [?] 等; 仿真器如 TACTO [?], Taxim [?]
- **多模态型:** 仿人类皮肤, 融合压力、接近、加速度、温度等多模态信息, 采用柔性材料

与模块化设计。

6.4.2 数据集

- **非视觉数据集：**BioTac 系列采集电极值、力向量与接触位置，面向力/抓取估计。
- **视觉数据集：**由 GelSight、DIGIT 等采集高分辨率凝胶变形图像，包含家居物品、自然环境、多材质抓取样本，并易于与图像、语言、音频对齐，故在具身智能中占主流。

6.4.3 触觉感知任务

1. 估计

- **触觉图像生成：**从 RGB-D 等视觉模态生成触觉图像，早期用 CNN [?, ?]，近期采用扩散模型 [?, ?]。
- **物体重建：**2D 重建关注形状与分割 [?, ?]；3D 重建涵盖表面、姿态乃至全场景，方法从数学优化、自编码器到 NeRF/3D-GS 融合视觉-触觉特征 [?, ?]。

2. 机器人操作核心为缩小 Sim-to-Real gap:

- **强化学习：**Visuotactile-RL [?], RotateIt [?], 纯触觉推动 [?], AnyRotate [?]
- **GAN 方法：**ACTNet [?]（像素级对抗适应）、STR-Net [?]（特征级适应），工具如 Tactile Gym 2.0 [?]

3. 识别

- **传统方法：**自编码器降维 [?], 多模态融合 [?, ?, ?], 对比学习绑定触觉与其他模态 [?]
- **LLM/VLM：**对比预训练对齐触觉-视觉-语言，再用 LLaMA 等微调完成触觉描述等任务 [?, ?, ?]

6.4.4 困难与挑战

- 传感器固有缺陷：非视觉型数据低维，视觉/电子皮肤精度高但昂贵。
- 数据采集困难：同步触觉-视觉数据成本高。
- 标准化缺失：传感器接口与数据格式各异，阻碍大规模学习与公共数据集应用。

7 具身智能体

智能体（agent）是一个能够感知环境并采取行动以达成目标的自主实体。近年来，多模态大模型（Multimodal Large Models, MLMs）的突破性进展，进一步拓宽了智能体在真实场景中的应用边界。当这类模型被“具身化”（embodied）到物理载体后，其能力便从虚拟空间迁移到物理世界，形成“具身智能体”（embodied agent）[?]。图 ?? 概览了具身智能体的发展历程。

为了在信息丰富且动态的现实环境中可靠运行，具身智能体必须具备强大的多模态感知、交互与规划能力（见图 ??）。典型任务流程可分为两步：

1. **高层任务规划**：将抽象指令分解为可执行的子任务；
2. **低层动作规划**：利用感知-交互模型或策略函数逐步完成子任务，并将环境反馈回传至任务规划器以动态调整。

其中，任务规划主要发生在赛博空间（cyber space），强调“三思而后行”；动作规划则必须与物理环境深度耦合。如何将从网络中学得的能力对齐并泛化到真实世界，是具身智能体的核心挑战。

7.1 具身多模态基础模型

具身任务需要视觉识别场景、听觉理解指令、本体感知状态，并融合自然语言进行高层推理。为此，研究者提出了具身多模态基础模型（embodied multimodal foundation model）。Google DeepMind 的经验表明：利用大规模基础模型与多样化数据是当前最优路径。以 Robotic Transformer（RT）系列 [?] 为代表的工作，为后续研究奠定了重要基础。

模型演进 机器人基础模型经历了三次关键整合：

- **SayCan**[?]: 规划、可供性（affordance）、低层策略三模块分离；
- **Q-Transformer**[?]: 合并可供性与低层策略；
- **PaLM-E**[?]: 进一步统一规划与可供性；
- **RT-2**[?]: 首次将三大功能集成到单一 VLA（Vision-Language-Action）模型，支持链式思维推理，实现跨任务正迁移；
- **RT-H**[?]: 引入动作层级结构，通过中间语言动作桥接高层任务与低层控制。

数据瓶颈与对策 为缓解跨 embodiment 的泛化难题，Google 联合 33 家机构构建了 Open X-Embodiment 数据集 [?], 覆盖 22 种数据形态，并训练出通用模型 RT-X。与此同时，AutoRT[?] 让大语言模型自动指导机器人在新环境中采集多样数据，持续扩展数据分布。

效率优化 Transformer 在长上下文场景下效率不足（RT-2 推理频率仅 1-3 Hz）。近期工作尝试：

- **SARA-RT**[?]: 采用线性注意力机制；
- **RoboMamba**[?]: 引入 Mamba 结构，推理速度提升 ~ 7 倍。

动作层级的细化 生成式 VLA 模型擅长高层规划，却在低层动作参数化上表现欠佳。RT-Trajectory[?] 通过视觉轨迹提示弥合高层指令与低层控制之间的鸿沟；RT-H 则用语言动作作为中间抽象，实现细粒度任务推理。未来方向是将强化学习融入 VLA 训练，使其在真实世界中自主学习并优化低层物理交互。

7.2 具身任务规划

以“把苹果放到盘子上”为例，任务规划器输出“找苹果 → 抓苹果 → 找盘子 → 放苹果”，而不涉及如何抓取或导航的细节。传统方法依赖符号规划（STRIPS、PDDL）或搜索（MCTS、A*），规则刚性、难以适应动态环境。大语言模型（LLM）的出现，使得基于世界知识的零样本规划成为可能。

7.2.1 利用大语言模型的涌现能力进行规划

早期方法在 ALFRED/ALFWorld 上微调 BERT 类模型 [?]，受限于训练分布。LLM 则凭其涌现能力与链式思维直接分解复杂任务：

- Translated LM、Inner Monologue[?]：零样本生成可执行步骤；
- ReAct[?]：结合推理与行动轨迹；
- ReAd[?]：多智能体协作自我精修计划；
- 记忆增强方法 [?]：将成功经验抽象为可复用技能；
- 代码即规划 [?]：用可执行代码代替自然语言，提高精确性；
- 多轮纠错：Socratic Planner[?] 通过苏格拉底式提问抑制幻觉。

然而，缺乏视觉反馈常导致规划与现实不符。执行阶段引入视觉信息可显著提升成功率。

7.2.2 融合视觉信息的规划

将检测结果（物体标签、位姿）实时反馈给 LLM，可在运行时修正不合理步骤 [?, ?]。SayPlan 采用分层 3D 场景图，支持跨楼层、跨房间的长程任务；ConceptGraphs 则提供开放世界检测并以代码形式输出规划，效率更高。但仅依赖标签仍可能遗漏关键上下文（如毛巾被锁在柜中）。因此，需要更鲁棒的多模态融合与历史上下文推理，以提升智能体对复杂环境的理解。

7.2.3 基于视觉语言模型的规划

视觉语言模型（VLM）可在潜在空间对齐视觉与语言特征，捕捉难以言表的上下文。Embodied-Former[?] 统一视觉、文本与本体状态；LEO[?] 编码 2D egocentric 图像与 3D 场景；EIF-Unknown[?] 将体素语义特征送入 LLaVA。然而，RoboGPT[?] 实验表明：任务规划准确率 96%，而整体完成率仅 60%，动作规划仍是瓶颈。

7.3 具身动作规划

任务规划给出子任务粒度不足，动作规划必须直面环境的不确定性。现有两大范式：

7.3.1 调用外部策略 API

LLM 将子任务映射到预训练策略模型（如 CLIPort[?]) 的 API 调用。Reflexion[?] 在运行期微调策略；DEPS[?] 让 LLM 扮演多角色，在交互中零样本组合新技能。该范式解耦高层决策与低层控制，便于模块化开发与热插拔，但策略质量直接决定整体性能，且 API 调用引入延迟。

7.3.2 端到端 VLA 模型

感知、决策、执行在同一 VLA 模型内完成，降低通信开销，支持实时闭环反馈。然而，端到端训练成本高，且 LLM 缺乏显式物理世界模型，难以精确模拟动力学，从而限制了在复杂长程任务中的可靠性。

7.4 仿真到现实适应 (Sim-to-Real Adaptation)

在具身人工智能 (Embodied AI) 中，仿真到现实 (Sim-to-Real) 适应指的是将在仿真环境 (赛博空间) 中习得的能力或行为迁移到现实场景 (物理世界) 的过程。它涉及验证和改进在仿真中开发的算法、模型和控制策略的有效性，以确保其在物理环境中能够鲁棒且可靠地运行。为实现仿真到现实适应，**具身世界模型 (Embodied World Model)**、**数据采集与训练方法 (Data Collection and Training Methods)** 以及 **具身控制算法 (Embodied Control Algorithms)** 是三个关键组成部分。

7.4.1 具身世界模型 (Embodied World Model)

仿真到现实适应需要在仿真中创建与现实世界环境高度相似的世界模型，以帮助算法在迁移时获得更好的泛化能力。世界模型方法旨在构建一个端到端的模型，通过以生成或预测的方式预测下一个状态来做出决策，实现从视觉到动作、甚至从任意输入到任意输出的映射。这类世界模型与**视觉语言动作模型 (Vision-Language-Action, VLA)** 模型的最大区别在于：VLA 模型首先在大型互联网数据集上进行预训练以获得高层次涌现能力，然后再与真实世界机器人数据进行联合微调；而世界模型则完全基于物理世界数据从头训练，随着数据量的增长逐步发展出高级能力。然而，它们本质上仍是低级的物理世界模型，某种程度上类似于人类神经反射系统的机制。这使得它们更适用于输入和输出都相对结构化的场景，例如自动驾驶（输入：视觉；输出：油门、刹车、方向盘）或物体分拣（输入：视觉、指令、数

值传感器；输出：抓取目标物体并将其放置到目标位置）。它们不太适合泛化到非结构化的复杂具身任务。

参见图 15 说明

图 15：具身世界模型大致可分为三种类型。(a) **基于生成的方法 (Generation-based Methods)**：使用自编码器框架训练学习输入空间与输出空间之间的转换关系。(b) **基于预测的方法 (Prediction-based Methods)**：可视为更通用的框架，在潜空间 (Latent Space) 中训练世界模型。(c) **知识驱动的方法 (Knowledge-driven Methods)**：将人工构建的知识注入模型，赋予模型世界知识，以获得符合给定知识约束的输出。注：虚线框内的组件是可选的。

表 XI：总结了本节讨论的具身世界模型方法（见表 XI）。

学习世界模型在物理仿真领域前景广阔。与传统仿真方法相比，它具有显著优势，例如能够基于不完整信息进行交互推理、满足实时计算需求，并随时间推移提高预测准确性。此类世界模型的预测能力至关重要，它使机器人能够发展出在人类世界中操作所需的物理直觉。如图 15 所示，根据世界环境的学习流程，它们可分为**基于生成的方法**、**基于预测的方法**和**知识驱动的方法**。我们在表 XI 中对提及的方法进行了简要总结（见表 XI）。

1) 基于生成的方法 (Generation-based Methods) 随着模型和数据规模的不断增长，生成模型已展现出理解和生成符合物理规律的图像（例如 World Models [338]）、视频（例如 Sora [17], Pandora [339]）、点云（例如 3D-VLA [340]）或其他格式数据（例如 DWM [341]）的能力。这种能力表明生成模型可以学习并内化世界知识。具体来说，在接触海量数据后，生成模型不仅能捕捉数据的统计特性，还能通过其内部结构和机制模拟现实世界的物理和因果关系。因此，这些生成模型可被视为不仅仅是简单的模式识别工具：它们展现出世界模型的特性。因此，可以利用嵌入生成模型中的世界知识来提升其他模型的性能。然而，生成模

型也存在一定的局限性和缺点，例如数据分布偏差、训练资源消耗大、可解释性差等。

2) 基于预测的方法 (Prediction-based Methods) 基于预测的世界模型通过构建和利用内部表征来预测和理解环境。它根据提供的条件在潜空间中重构相应特征，从而捕捉更深层次的语义和关联的世界知识。与像素级信息相比，潜特征能够对各种形式的知识进行抽象和解耦，使模型能更有效地处理复杂任务和场景，并提升其泛化能力 [355]。然而，此类模型在处理先前未见的环境和条件时，可能会表现出局限性和不稳定性，且在潜空间中解耦的世界知识可能存在可解释性问题。

3) 知识驱动的方法 (Knowledge-driven Methods) 知识驱动的世界模型将人工构建的知识注入模型，赋予其世界知识。这种方法在具身人工智能领域展现出广阔的应用潜力。例如，在 real2sim2real 方法 [357] 中，利用现实世界知识构建符合物理规律的仿真器，然后用于训练机器人，从而增强模型的鲁棒性和泛化能力。此外，人工构建常识或符合物理规律的知识并将其应用于生成模型或仿真器也是一种常见策略（例如 ElastoGen [350], One-2-3-45 [351], PLoT [349]）。一些方法将人工创建的物理规则与大型语言模型（LLM）或多模态语言模型（MLM）相结合，通过自动空间布局优化生成多样且语义丰富的场景。

7.4.2 数据采集与训练 (Data Collection and Training)

对于仿真到现实适应，高质量的数据至关重要。传统的数据采集方法依赖昂贵的设备、精确的操作，且耗时耗力，通常缺乏灵活性。最近，一些高效且经济的方法被提出，用于高质量演示数据的采集和训练。

参见图 16 说明

图 16: 演示数据采集示意图。左侧黄色框展示了 Franka 和 WidowX 机械臂的操作演示，蓝色框展示了人类演示。中间黄色框展示了 UR5e 和 Franka 机械臂

在仿真环境中的操作场景，蓝色框展示了标注的仿真数据。右侧紫色框展示了这些数据集的数据格式。

1) 现实世界数据 (Real-World Data) 在大规模、丰富的数据集上训练大容量模型，已在有效解决下游应用方面展现出卓越的能力和显著的成功。例如，Open X-Embodiment [303] 是一个来自 22 种不同机器人的具身数据集，包含 527 种技能和 160,266 个任务。UMI [358] 提出了一个数据采集和策略学习框架，能够便携、低成本地采集信息丰富的挑战性双手操作和动态演示数据。Mobile ALOHA [359] 是一个低成本全身移动操作系统，可用于采集在全身移动条件下的双手操作任务数据。

2) 仿真数据 (Simulated Data) 在仿真环境中采集数据不需要大量资源，通常可以通过程序自动化完成，节省大量时间。CLIPORT [294] 和 Transporter Networks [361] 从 Pybullet 仿真器收集演示数据用于端到端网络模型训练，并成功地将模型从仿真迁移到现实世界。GAPartNet [362] 构建了一个大规模的部件中心化交互数据集 GAPartNet，为感知和交互任务提供了丰富的部件级标注。

3) 仿真到现实范式 (Sim-to-Real Paradigms) 最近，出现了一些仿真到现实范式，旨在通过在仿真环境中进行广泛学习，然后迁移到现实环境，从而减少对大量且昂贵的现实世界演示数据的需求。

参见图 17 说明

图 17：实现缩小仿真与现实差距的五种途径。**Real2Sim2Real** 通过重建真实场景来缩小差距；**TRANSIC** 通过人工校正干预来补偿仿真到现实的迁移差距；**Domain Randomization** 通过模拟环境多样性来增强模型的迁移适应性；**System Identification** 通过提高仿真与现实环境的相似性来缓解仿真与现实差

距；**Lang4Sim2Real** 使用自然语言作为桥梁连接两个领域，学习不变图像表征以减少视觉差距。

- **Real2Sim2Real** [363]: 通过在“数字孪生”仿真环境中训练强化学习策略来增强现实场景中的模仿学习。
- **TRANSIC** [364]: 通过允许在现实场景中进行实时人工干预来纠正机器人行为，从而缩小仿真到现实的差距。
- **Domain Randomization** [365, 366, 367]: 通过在仿真训练过程中引入参数随机化，增强模型对现实场景的泛化能力。
- **System Identification** [368, 369]: 构建现实环境中物理场景的精确数学模型，使仿真环境与现实环境高度相似。
- **Lang4Sim2Real** [370]: 利用自然语言作为桥梁来解决仿真到现实的差距，方法是使用图像文本描述作为跨领域的统一信号。

7.4.3 具身控制 (Embodied Control)

具身控制通过与环境的交互进行学习，并利用奖励机制优化行为以获得最优策略，从而规避传统物理建模方法的缺点。具身控制方法可分为两种类型：

1. **深度强化学习 (Deep Reinforcement Learning, DRL)**: DRL 能够处理高维数据并学习复杂的行为模式，适用于决策和控制。例如，混合动态策略梯度 (HDPG) [371] 被提出用于双足运动，DeepGait [372] 是一种用于地形感知运动的神经网络策略。
2. **模仿学习 (Imitation Learning)**: DRL 的缺点是需要大量试错数据。为解决此问题，引入了模仿学习，其目标是通过收集高质量演示来最小化数据使用量。代表性方法有 ALOHA [373] 和 Mobile ALOHA [359]。

参见图 18 说明

图 18: 多种运动模式的具身控制示例，展示了机器人的敏捷移动和交互能力。左侧橙色框展示了四足机器人和双足机器人的运动；中间红色框展示了 Atlas 机器人爬楼梯、TELESAR V 机器人写字、Unitree H1 击掌以及波士顿机器人跳跃的运动场景；绿色框展示了多机器人协同控制、路径寻找和路径规划。

具身控制整合了强化学习（RL）和仿真到现实技术，通过与环境交互来优化策略，使其能够探索未知领域，并适应非结构化环境。未来，在预训练和微调之后，仍然需要 RL 来确保模型与物理世界对齐，从而在现实环境中有效部署。

7.4.4 万机归一 (All Robots in One)

重大的数据层面限制持续阻碍着鲁棒、通用具身智能体的发展，特别是在标准化格式、多样性和数据量方面。为克服这些挑战，引入了 **ARIO (All Robots In One)** [387] 标准，这是一个新的数据集标准，旨在优化现有数据集并促进开发更具通用性和普适性的具身 AI 智能体。ARIO 标准以统一格式记录具有不同形态机器人的控制和运动数据，解决了当前数据集的局限性。

基于 ARIO 标准，进一步开发了一个统一的大规模 **ARIO 数据集**，该数据集包含约 300 万条记录（episodes），来自 258 个系列（series）和 321,064 个任务（tasks）。该项目可在 https://imaei.github.io/project_pages/ario 获取。

8 具身智能的前沿研究方向

1. 跨场景泛化与物理部署

- **VLN-PE 平台**（同济大学 & 上海 AI Lab）

支持人形、四足和轮式机器人的物理级视觉语言导航（VLN），系统评估了扩散模型、大语言模型等在真实物理挑战（如光照变化、碰撞跌倒）中的表现，揭示了仿真与现实的“具身差距”。

- **UnrealZoo 虚拟世界**（北师大等）

构建 100 个高逼真开放世界场景，涵盖从古代到科幻的多样化环境，通过强化学习和 GPT-4o 测试智能体在非结构化地形中的导航鲁棒性，发现当前模型与人类表现仍存显著差距。

2. 3D 空间理解与导航

- **IGL-Nav 系统**（清华大学）

基于 3D 高斯点云技术实现实时场景重建，允许机器人通过单张任意角度照片定位目标位置。其“粗定位到精定位”分层策略在自由视角导航任务中成功率超 73.5%，显著优于传统神经辐射场方法。

- **3D-R1 空间推理框架**

融合强化学习（GRPO 算法）与推理链（Chain-of-Thought），在 7 大任务（如 3D 问答、动作规划）中达到 SOTA。其动态视角选择机制优化了信息获取效率，解决了遮挡和视角冗余问题。

3. 自主操作与技能学习

- 手术机器人自主操作（香港中文大学 & 康诺思腾）

全球首例临床场景下自主手术验证，通过 VPPV 框架（视觉解析 + 策略学习 + 伺服控制）完成活体动物组织夹闭等任务，实现“零样本迁移”。

- 墨甲机器人开门技能

基于端到端强化学习，通过数百万次仿真训练掌握车门把手的动态抓握与全身协同发力，突破非结构化环境中的力控稳定性瓶颈。

4. 记忆架构与终身学习

- RoboMemory 框架（中科大）

模仿人脑四重记忆系统（空间/时间/情节/语义记忆），动态知识图谱记录物体关系，任务重复成功率提升 75%。其“睡眠式记忆整理”机制筛选关键经验，避免信息过载。

5. 多模态交互与人机协作

- HAM-Nav 手绘地图导航（多伦多大学）

利用视觉语言模型（VLMs）解析不精确的手绘地图，通过自适应视觉提示（SVAP）实现零样本跨环境泛化，适应零售、救援等动态场景。

6. “一脑多态” 机器人架构

- 优艾智合凌枢机器人

全球首创的通用智能大脑适配多形态本体（如人形、轮式），在半导体制造中完成精密辅料装填，在能源领域实现复杂环境巡检。

表 3: 具身智能前沿研究方向及代表成果

研究方向	代表成果	核心技术	应用场景
跨场景泛化	VLN-PE 平台	物理仿真、多机器人适配	家居/灾难救援导航
3D 空间理解	IGL-Nav 系统	3D 高斯点云、分层定位	服务机器人、自动驾驶
自主操作	手术机器人	视觉伺服控制、Sim2Real 迁移	微创外科
记忆架构	RoboMemory	动态知识图谱、记忆整理机制	家庭服务机器人
多模态交互	HAM-Nav	视觉语言模型、拓扑地图生成	零售/救援导航

计算机图形学的关键应用

1. 高保真仿真环境构建

- **场景逼真度：**UnrealZoo 通过 Unreal Engine 5 实现照片级渲染，支持动态光影、材质物理特性模拟，为视觉导航任务提供接近真实的训练场。
- **场景扩展性：**中国移动“灵霄”平台集成万级可交互家庭资产库（如厨房器具），结合高精度三维重建技术，实现分钟级场景搭建。

2. 传感器仿真与数据生成

- **多模态数据合成**：“灵霄”平台模拟 RGB-D 相机、激光雷达等信号，生成时序对齐的感知数据，解决真实数据采集成本高的问题。
- **光照与物理扰动**：VLN-PE 平台在 NVIDIA Isaac Sim 中模拟不同光照条件，验证模型鲁棒性；引入摔倒率（FR）等指标量化物理挑战影响。

3. 物理引擎与动作合成

- **刚体/柔体动力学**：手术机器人仿真平台 SurRoL 模拟组织形变与器械交互，为 VPPV 策略提供训练数据。
- **运动控制优化**：墨甲机器人通过物理仿真预训练全身协同动作（如腿部屈伸抗车门反力），再迁移至实体机器人。

4. 3D 重建与场景理解

- **实时高斯点云重建**：IGL-Nav 系统通过神经网络预测点云参数，在线更新场景模型，支持机器人探索未知环境。
- **语义地图构建**：VLN-PE 利用 3D 高斯绘制（3DGS）重建实验室环境，生成带语义标注的导航基准。

5. 实时渲染与视觉反馈

- **光线追踪与并行加速**：UnrealZoo 优化渲染管线，在复杂场景中保持高帧率，满足多智能体交互的实时性需求。
- **视觉伺服控制**：手术机器人通过立体内窥镜渲染图像，实现毫米级器械定位。

表 4: 计算机图形学在具身智能中的关键技术

技术方向	应用案例	核心价值
高保真渲染	UnrealZoo 场景	提供接近真实的视觉训练环境
物理引擎	墨甲机器人开门仿真	模拟力学交互，优化动作策略
3D 高斯点云重建	IGL-Nav 实时定位	高效构建可迭代的场景模型
传感器仿真	“灵霄”多模态数据生成	低成本生成标注数据，替代真实采集
GPU 并行加速	多机器人协同训练	提升大规模仿真效率

融合趋势与挑战

1. 仿真到现实的迁移（Sim2Real）

- 领域随机化：如墨甲机器人在训练中随机化车门阻力、光照参数，提升策略泛化性。
- 闭环优化：中国移动“灵数”系统将真实环境数据反馈至仿真管线，迭代修正物理参数。

2. 多模态感知融合

图形学推动视觉-触觉-力觉联合仿真，如手术机器人同时模拟组织形变（视觉）与夹持反馈（触觉）。

3. 计算效率优化

- 轻量化渲染：3D-R1 框架动态选择关键视角，减少冗余计算。
- 分布式训练：“凌霄”平台支持千台机器人并行仿真，加速强化学习收敛。

4. 标准化与开源生态

- VLN-PE、UnrealZoo 等平台开源代码与环境资产，降低研究门槛。
- 仍需统一评测基准（如具身差距量化指标）和跨平台接口协议。

9

10 结论

具身智能的前沿突破依赖于计算机图形学的深度支撑：**仿真技术**解决了数据稀缺与试错成本问题，**3D 重建与渲染**提升了环境理解的几何真实性，**物理引擎**则保障了动作策略的物理可行性。未来，随着神经渲染、多模态传感器仿真等技术的发展，“虚拟预训练-现实微调”的范式将加速具身智能在医疗、工业、家庭服务等场景的落地，最终实现“硅基生命”与物理世界的无缝交互。

11 展望